L'intelligence artificielle : une mise en contexte

Des données aux modèles modernes

Université de Montpellier – LIRMM

HAI817I

Pascal Poncelet
Pascal.Poncelet@lirmm.fr
http://www.lirmm.fr/~poncelet

Plan

1. Des traces aux données
2. Écriture et supports
3. Diffuser l'information
4. Automatiser le calcul
5. Changer d'échelle : réseaux et Internet
6. Historique du Machine Learning
7. Deep Learning
8. IA moderne : modèles de langage

Représenter le monde

45 000 – 10 000 av. J.-C.

-40k -10k -3k 1450 1950 1990

Peintures animales, grotte de Lascaux
(France, ∼17 000 av. J.-C.)
Homo sapiens
Source : Wikimedia Commons

- Contexte :
  - réalisées par Homo sapiens (Paléolithique supérieur),
  - sociétés de chasseurs-cueilleurs.
- Hypothèses sur les rôles :
  - transmission de récits (chasse, événements),
  - pratiques symboliques et rituelles,
  - mémorisation et partage collectif.

Mots-clés : représentation, mémoire, transmission

Marquer la présence humaine

40 000 – 15 000 av. J.-C.

-40k -10k -3k 1450 1950 1990

Mains négatives, Cueva de las Manos (Argentine)
~9 000 av. J.-C., *Homo sapiens*
Source : Wikimedia Commons

- Contexte :
  - marquage intentionnel des parois,
  - gestes répétés et collectifs,
  - groupes humains structurés.
- Hypothèses sur les rôles :
  - marquer un lieu ou un passage,
  - affirmer une présence ou une appartenance,
  - geste symbolique partagé.

Mots-clés : trace, identité, groupe

Structurer l'information

30 000 – 10 000 av. J.-C.

-40k -10k -3k 1450 1950 1990

Marques rupestres, Bhimbetka (Inde)
∼30 000 – 10 000 av. J.-C.
Source : Wikimedia Commons

- Contexte :
  - apparition de signes simples et répétés,
  - structuration progressive de l'information.
- Hypothèses :
  - comptage (jours, proies, événements),
  - catégorisation rudimentaire,
  - conservation d'informations hors oral.

Mots-clés : comptage, structure, abstraction

Les limites des proto-données

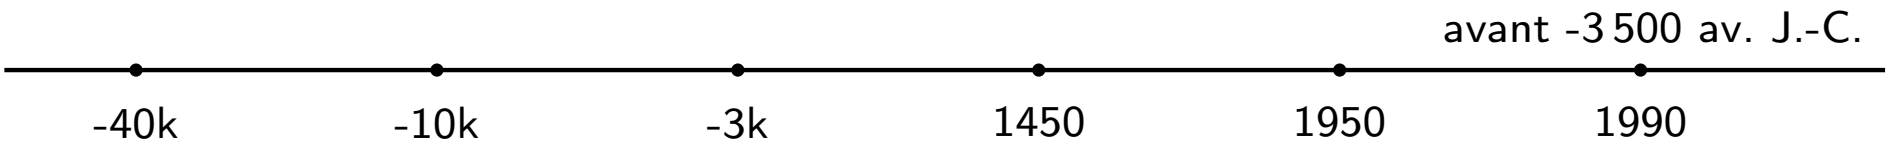

Ces traces fonctionnent tant que :

- les groupes sont réduits,
- le contexte est partagé,
- l'interprétation est implicite.

Elles deviennent insuffisantes à grande échelle

De la trace au symbole

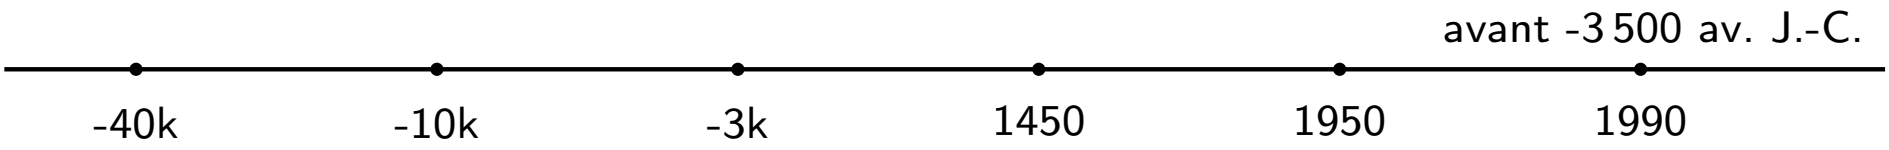

Quand les sociétés deviennent plus complexes,
les traces doivent être :

- partagées,
- standardisées,
- interprétables par tous.

Apparition de systèmes d'écriture

Naissance de l'écriture cunéiforme

vers -3 400 av. J.-C.

-40k -10k -3k 1450 1950 1990

Tablette sumérienne en écriture cunéiforme
Mésopotamie, ∼-3 200 av. J.-C.
Source : Wikimedia Commons

- Contexte :
  - sociétés agricoles sédentaires,
  - croissance démographique,
  - échanges et administration.
- Fonction initiale :
  - gestion des ressources (grains, bétail),
  - comptabilité et fiscalité,
  - mémoire externe fiable.

Mots-clés : administration, comptabilité, externalisation

Standardiser l'information

de -3 200 à -2 500 av. J.-C.

-40k -10k -3k 1450 1950 1990

Détails de signes cunéiformes
Source : Wikimedia Commons

- Évolution majeure :
  - des images vers des signes abstraits,
  - réduction de l'ambiguïté.
- Conséquences :
  - interprétation indépendante du locuteur,
  - transmission à grande échelle,
  - apprentissage formalisé (scribes).

Mots-clés : abstraction, norme, interprétabilité

Écriture hiéroglyphique : une autre approche

vers -3 200 av. J.-C.

-40k -10k -3k 1450 1950 1990

Hiéroglyphes égyptiens, tombe de Séthi Ier
Nouvel Empire, ∼-1 300 av. J.-C.
Source : Wikimedia Commons

- Contexte :
  - civilisation étatique centralisée,
  - administration, religion, pouvoir.
- Spécificités :
  - signes figuratifs et symboliques,
  - écriture à forte dimension idéologique,
  - usage monumental (temples, tombes).

Mots-clés : symbole, pouvoir, sacralisation

Le papyrus : une révolution du support

vers -3 000 av. J.-C.

-40k -10k -3k 1450 1950 1990

Papyrus d'Ani (Livre des Morts)
Égypte, ∼-1 250 av. J.-C.
Source : Wikimedia Commons

- Rupture majeure :
  - support léger et transportable,
  - écriture déroulable et linéaire.
- Conséquences :
  - diffusion accrue de l'écrit,
  - archivage et transmission à distance,
  - spécialisation des scribes.

Mots-clés : support, portabilité, diffusion

Avant l'imprimerie : supports et diffusion

Antiquité – XVe siècle

-40k -10k -3k 1450 1950 1990

Manuscrit médiéval enluminé
Source : Wikimedia Commons

- Supports principaux :
  - papyrus (fragile, coûteux),
  - parchemin (résistant mais cher),
  - manuscrits copiés à la main.
- Contraintes :
  - production lente,
  - erreurs de copie,
  - diffusion très limitée.

Mots-clés : support, copie, rareté

Accès à l'information avant l'imprimerie

Antiquité – XVe siècle

-40k -10k -3k 1450 1950 1990

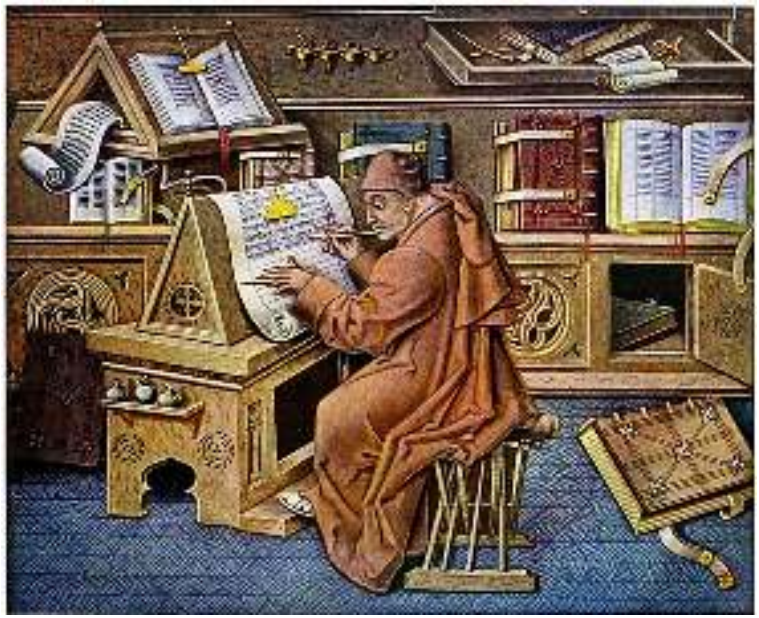

Scribe médiéval copiant un manuscrit
Source : Wikimedia Commons

- Accès réservé à :
  - clergé et institutions religieuses,
  - administrations et élites politiques,
  - une minorité de lettrés.
- Conséquences :
  - faible alphabétisation,
  - diffusion lente des idées,
  - contrôle du savoir.

Mots-clés : élite, contrôle, rareté

L'imprimerie : une rupture technologique

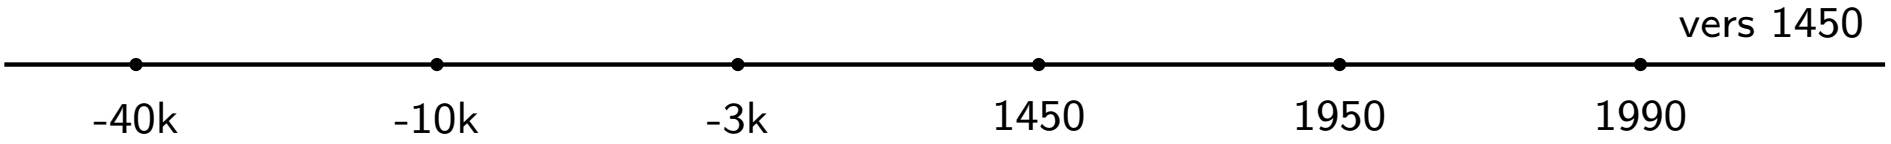

Presse à imprimer attribuée à Gutenberg XVe siècle — Source : Wikimedia Commons

- Innovations clés :
  - caractères mobiles métalliques,
  - presse mécanique,
  - encre adaptée.
- Effets immédiats :
  - reproduction rapide,
  - baisse des coûts,
  - standardisation des textes.

Mots-clés : automatisation, standardisation, reproductibilité

Le premier texte massivement diffusé

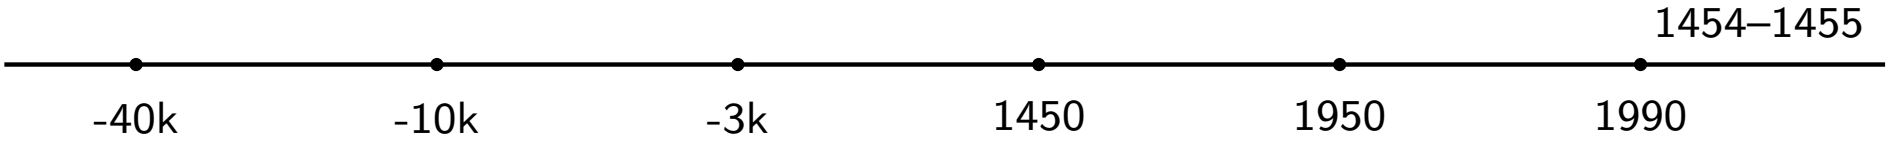

Bible de Gutenberg (Bible à 42 lignes)
Source : Wikimedia Commons

- Un texte central :
  - forte demande existante,
  - légitimité culturelle et religieuse.
- Une diffusion inédite :
  - centaines d'exemplaires,
  - circulation à l'échelle européenne.

Mots-clés : diffusion massive, référence, standard

Conséquences de l'imprimerie

XVe – XVIIe siècles

-40k -10k -3k 1450 1950 1990

Atelier d'imprimerie au XVIe siècle
Source : Wikimedia Commons

- Accès élargi à l'information :
  - augmentation progressive de l'alphabétisation,
  - émergence d'un public lecteur.
- Effets à long terme :
  - diffusion rapide des idées scientifiques,
  - remise en cause des autorités,
  - accélération du progrès.

Mots-clés : accès, diffusion, démocratisation

Conclusion : l'écriture devient mondiale

Antiquité – Moyen Âge

-40k -10k -3k 1450 1950 1990

Répartition des systèmes d'écriture dans le monde
(alphabets, abjads, logographies) — Source : Wikimedia Commons

- L'écriture apparaît sur tous les continents.
- Des systèmes différents, souvent indépendants.
- Un outil central de communication et d'organisation.

Mots-clés : diffusion, diversité, communication

L'imprimerie ne suffit pas

XVe – XIXe siècles

-40k -10k -3k 1450 1950 1990

École (XVIIIe siècle)
Source : Wikimedia Commons

- L'imprimerie diffuse les textes..
- ... mais la lecture ne devient massive que plus tard.
- Repères historiques :
  - 1763 : scolarité obligatoire en Prusse,
  - 1833 : loi Guizot (écoles primaires),
  - 1881–1882 : lois Ferry (gratuit, obligatoire, laïque).

Mots-clés : diffusion, école, démocratisation

Quand l'information devient un problème technique

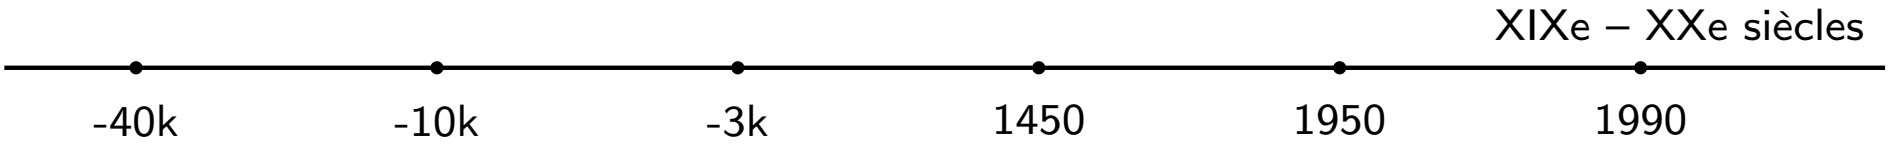

Une fois la lecture plus répandue,

le défi devient technique :

- stocker l'information,
- la structurer,
- la traiter.

Naissance des outils de calcul et de traitement automatique

Avant l'ordinateur : automatiser le calcul

XVIIe – XIXe siècles

-40k -10k -3k 1450 1950 1990

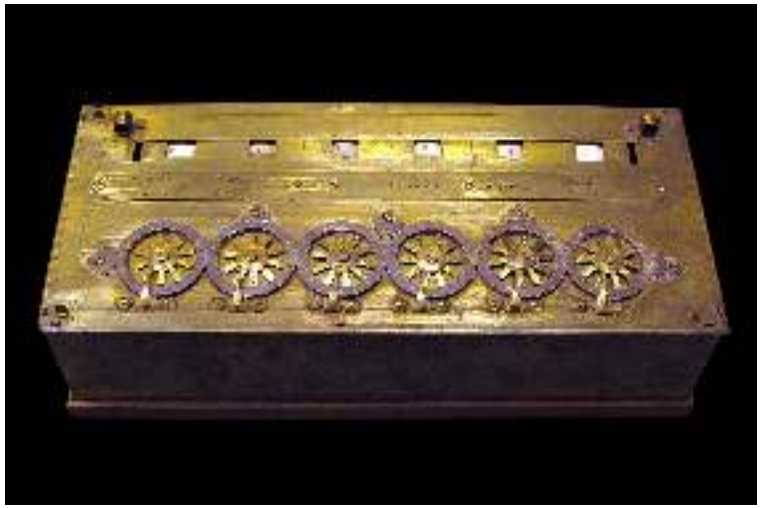

Pascaline, machine à calculer mécanique (1642)
Source : Wikimedia Commons

- Premières machines pour automatiser le calcul :
  - Blaise Pascal imagine une calculatrice mécanique.
  - Elle effectue des additions et des soustractions automatiquement.
- Objectif : limiter les erreurs et accélérer les tâches arithmétiques.

Mots-clés : calcul, automatisation, mécanique

La machine à différences de Charles Babbage

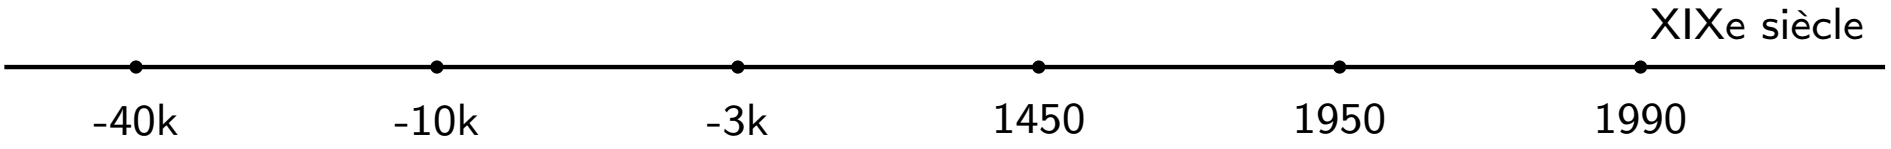

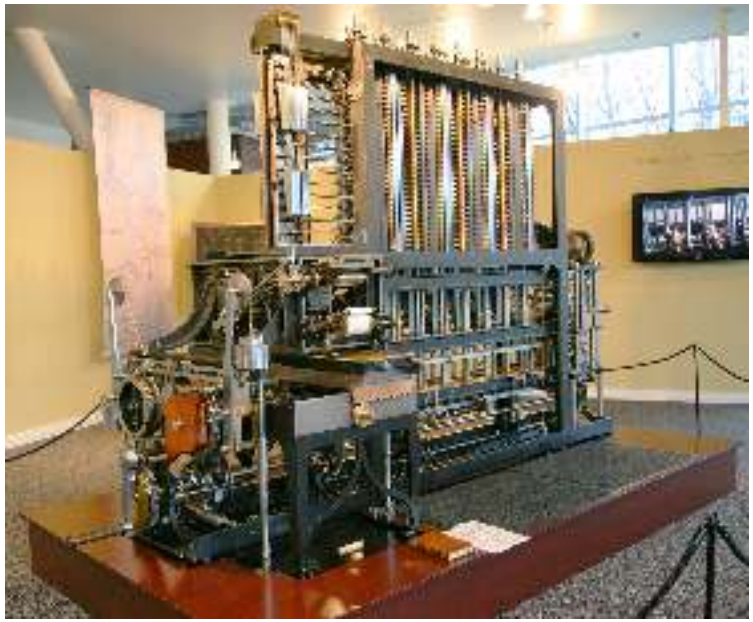

"Difference Engine" de Charles Babbage Reconstitution, XXIe siècle — Source : Wikimedia Commons

- Transition vers des machines "programmables".
- Babbage imagine une machine capable de :
  - calculer automatiquement des tables,
  - suivre des instructions séquentielles.
- Il préfigure ainsi l'ordinateur moderne.

Mots-clés : calcul, automatisation, prémices des ordinateurs

Alan Turing : le calcul universel

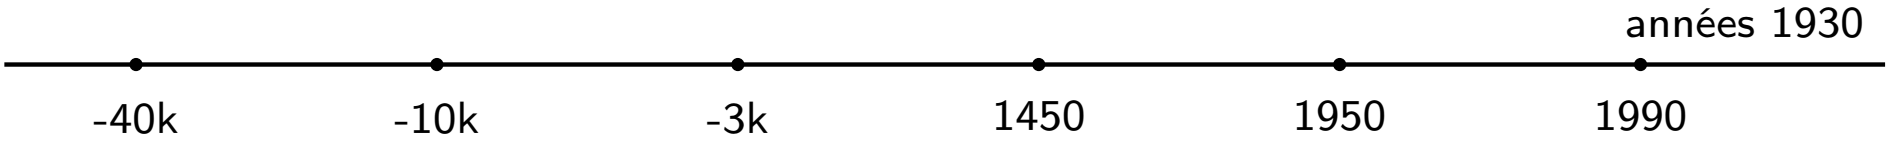

Alan Turing (1912–1954)
Source : Wikimedia Commons

- Idée centrale :
  - une machine capable d'exécuter **n'importe quel algorithme**.
- Principe :
  - un calcul = une suite d'instructions,
  - une même machine, plusieurs tâches.
- Impact :
  - fondement théorique de l'ordinateur moderne.

Mots-clés : algorithme, universalité, abstraction

Du concept à la machine : naissance de l'ordinateur

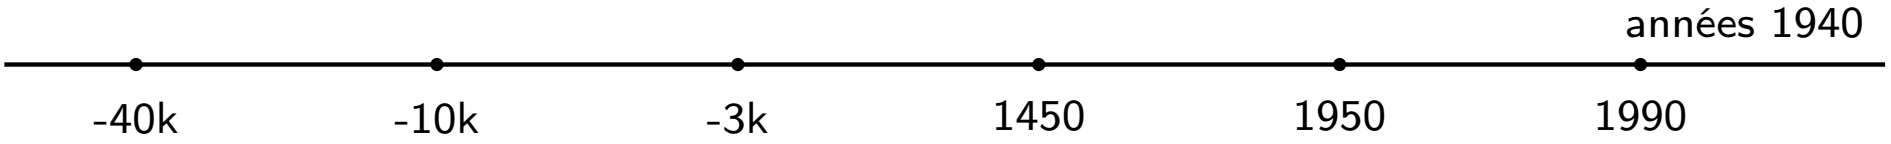

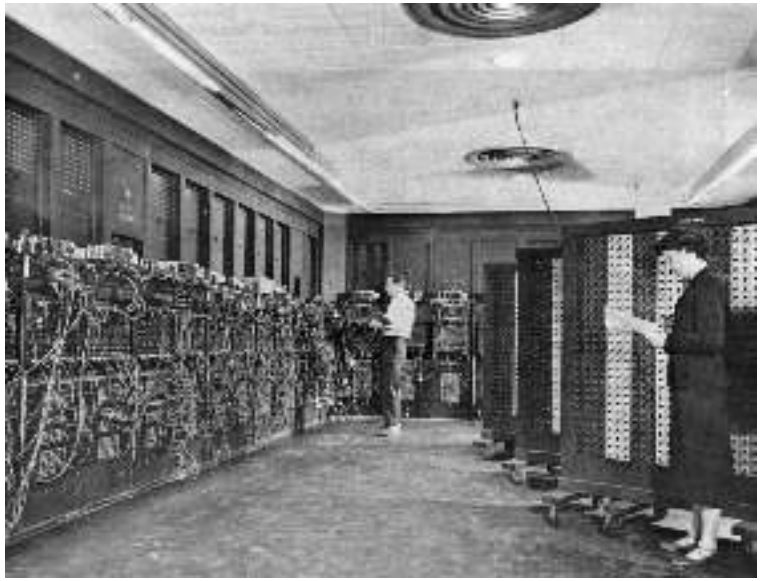

ENIAC (1945), premier ordinateur électronique programmable
Source : Wikimedia Commons

- Première réalisation concrète des idées de Turing.
- Caractéristiques :
  - électronique (tubes à vide),
  - programmable,
  - capable d'effectuer des calculs complexes.
- Limitations :
  - très volumineux,
  - consommation énergétique élevée,
  - programmation manuelle.

Mots-clés : électronique, calcul, programmation

Cartes perforées : stocker et structurer l'information

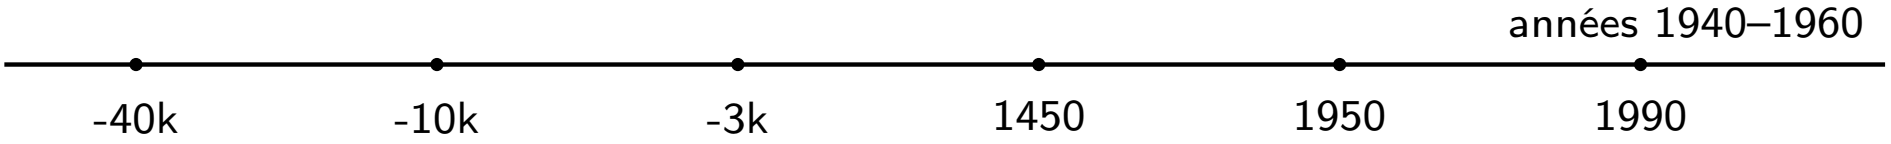

Cartes perforées IBM (milieu XXe siècle)
Source : Wikimedia Commons (NARA)

- Nouveau besoin :
  - stocker des données pour les machines.
- Principe :
  - information codée par des trous,
  - format standardisé et lisible par machine.
- Conséquence :
  - premières données structurées,
  - séparation données / calcul.

Mots-clés : stockage, structuration, données

Des cartes aux fichiers : supports numériques

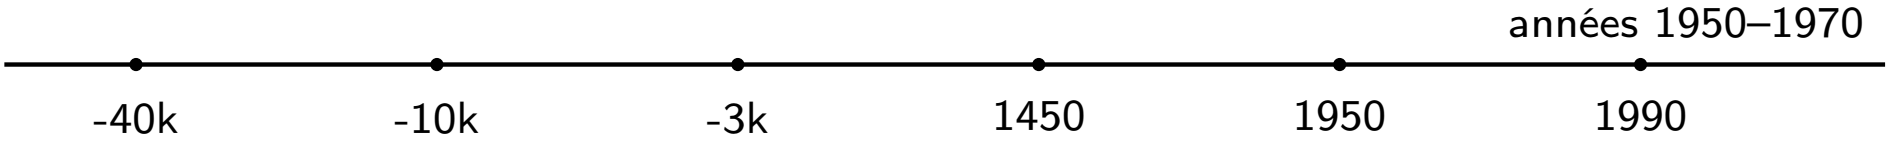

Bandes magnétiques pour le stockage informatique
Source : Wikimedia Commons

- Limites des cartes perforées :
  - volume important,
  - accès lent et séquentiel.
- Nouvelle étape :
  - stockage magnétique,
  - fichiers numériques persistants.
- Conséquence :
  - données réutilisables,
  - traitements plus complexes.

Mots-clés : fichier, persistance, stockage

Structurer l'information : tables et bases de données

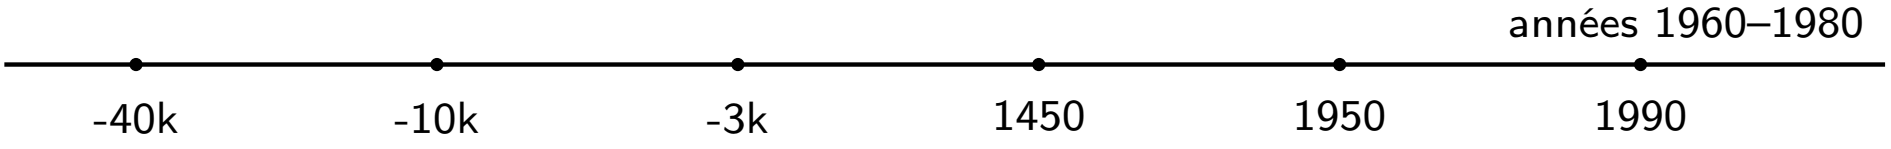

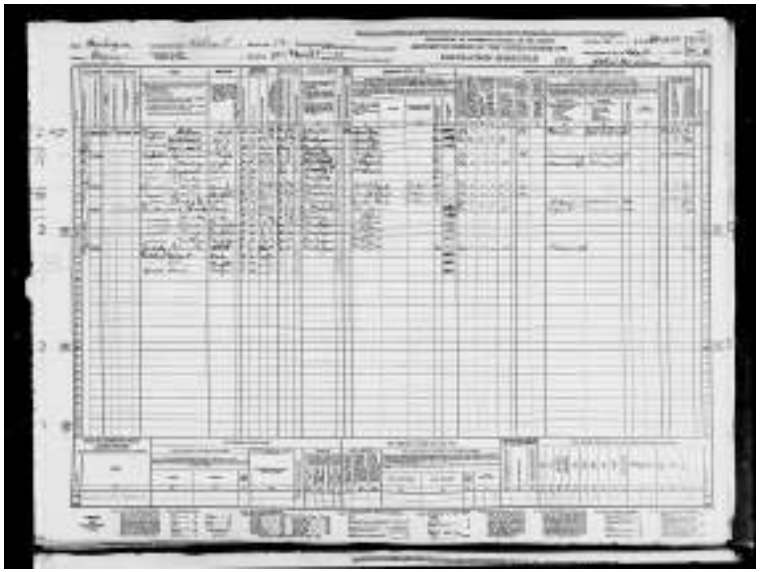

Registre de recensement structuré
(États-Unis, 1940)
Source : Wikimedia Commons

- Nouveau besoin :
  - organiser des volumes croissants d'informations.
- Principe :
  - données organisées en tables,
  - lignes = individus, colonnes = attributs.
- Conséquence :
  - interrogation systématique,
  - automatisation des traitements.

Mots-clés : structure, tables, données

Changer d'échelle : réseaux et Internet

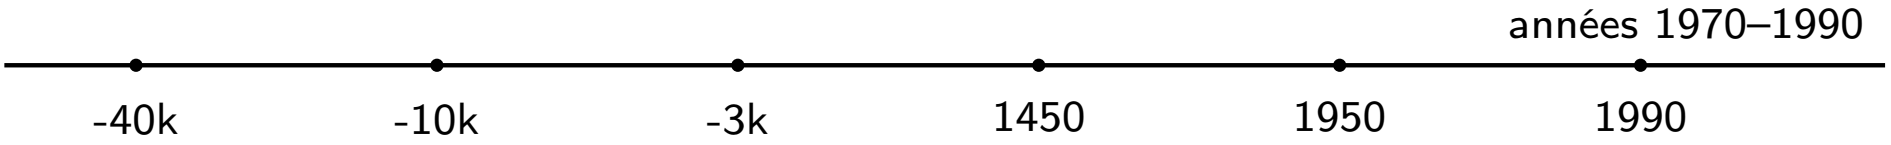

Les données sont désormais :

- stockées numériquement,
- structurées,
- traitées automatiquement.

Nouveau défi : les partager à grande échelle

Mise en réseau des machines

ARPANET : relier les machines

années 1960–1970

-40k -10k -3k 1450 1950 1990

Carte d'ARPANET (1974)
Source : Wikimedia Commons

- Objectif initial :
  - relier des ordinateurs distants,
  - partager des ressources de calcul.
- Principe :
  - réseau décentralisé,
  - échanges de données par paquets.
- Héritage :
  - fondation d'Internet.

Mots-clés : réseau, interconnexion, décentralisation

Internet : interconnecter le monde

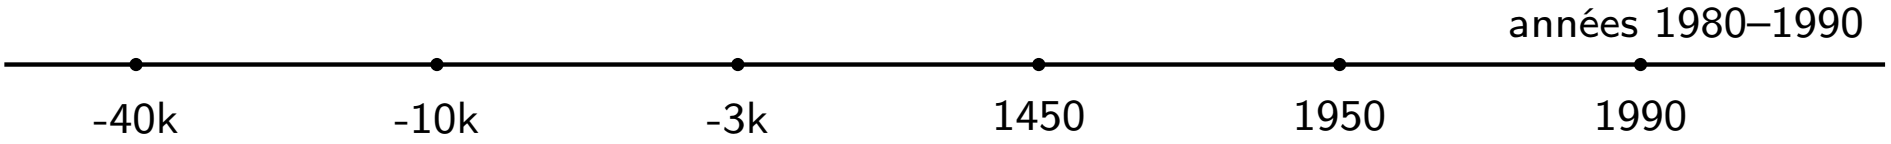

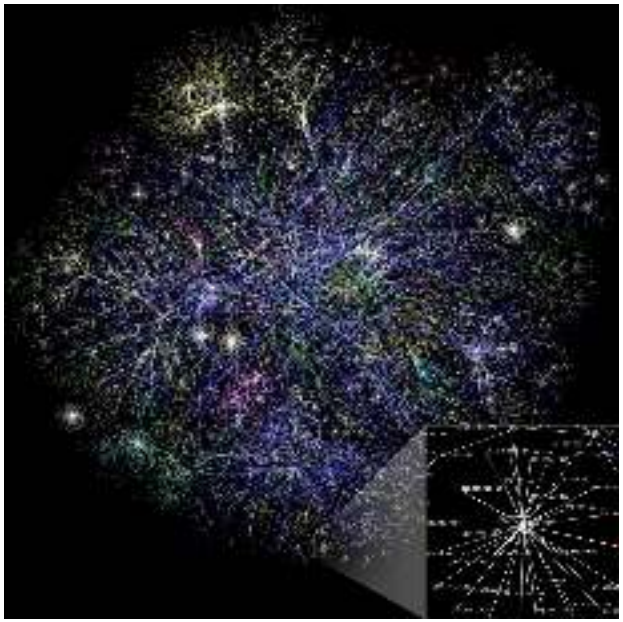

Interconnexion mondiale des réseaux informatiques
Source : Wikimedia Commons

- Évolution d'ARPANET :
  - interconnexion de réseaux hétérogènes,
  - protocoles communs (TCP/IP).
- Changement d'échelle :
  - circulation mondiale des données,
  - échanges quasi instantanés.
- Conséquence :
  - information distribuée,
  - dépendance au réseau.

Mots-clés : interconnexion, mondialisation, réseau

Le Web : rendre l'information accessible

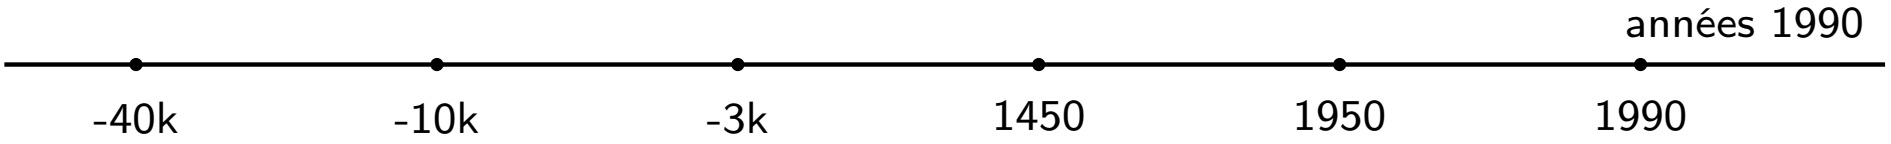

Premier serveur Web (CERN, 1991)
Source : Wikimedia Commons

- Objectif :
  - partager facilement des documents.
- Principes :
  - pages reliées par des liens,
  - accès via un navigateur.
- Rupture :
  - information accessible au grand public,
  - production massive de contenus.

Mots-clés : accessibilité, hypertexte, diffusion

Plateformes et réseaux sociaux : produire des données

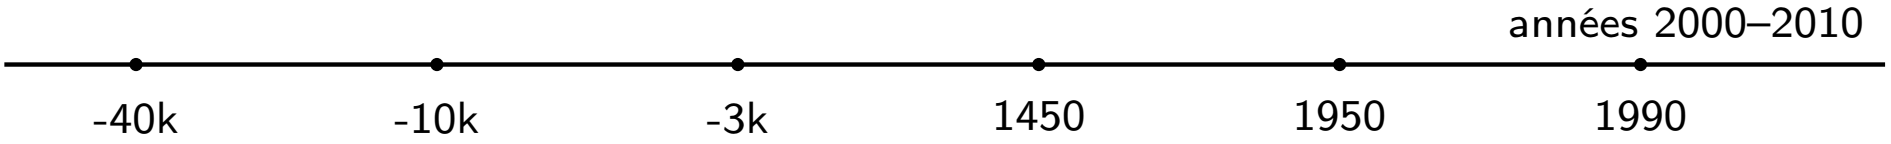

Plateformes et réseaux sociaux numériques
Source : Wikimedia Commons

- Changement majeur :
  - les utilisateurs deviennent producteurs de données.
- Nouveaux types de données :
  - textes, images, interactions,
  - données générées en continu.
- Conséquence :
  - volumes massifs,
  - analyse humaine impossible.

Mots-clés : plateformes, volume, données

Des données à l'apprentissage automatique

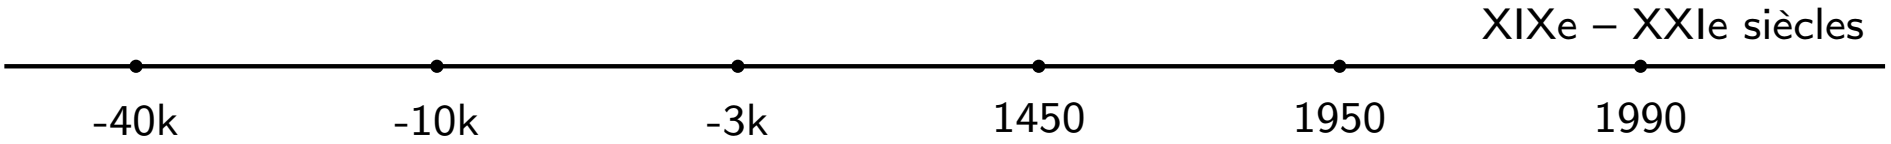

Une fois les données disponibles à grande échelle,

une question centrale apparaît :

comment apprendre automatiquement à partir des données ?

Naissance progressive du Machine Learning

Optimiser avant d'apprendre

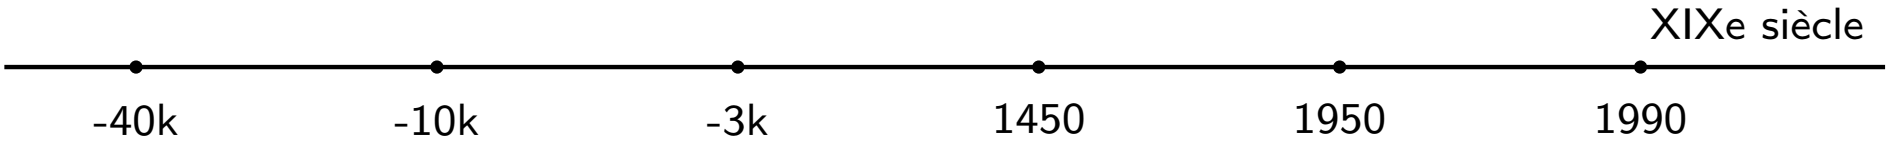

Augustin-Louis Cauchy (1789–1857)
Source : Wikimedia Commons

- Avant le Machine Learning :
  - résoudre des problèmes d'optimisation.
- Contribution clé :
  - fondements de l'optimisation continue,
  - idées de convergence par itérations.
- Héritage :
  - la descente de gradient moderne formalise ces idées au XXe siècle.
  - cœur de l'apprentissage moderne.

Mots-clés : optimisation, gradient, convergence

Régression linéaire : premier modèle appris

1805 – 1809

-40k -10k -3k 1450 1950 1990

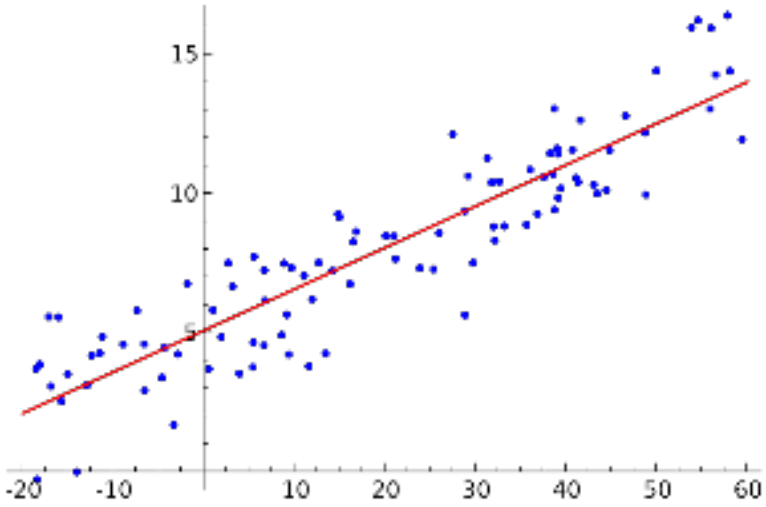

Illustration d'une régression linéaire
Source : Wikimedia Commons

- Origine :
  - méthode des moindres carrés (1805),
  - Legendre, puis Gauss.
- Principe :
  - ajuster un modèle simple aux données en minimisant une erreur globale.
- Importance historique :
  - premier modèle appris à partir des données,
  - fondation du ML moderne.

Mots-clés : moindres carrés, optimisation, apprentissage

Perceptron : premier modèle neuronal

1957

-40k -10k -3k 1450 1950 1990

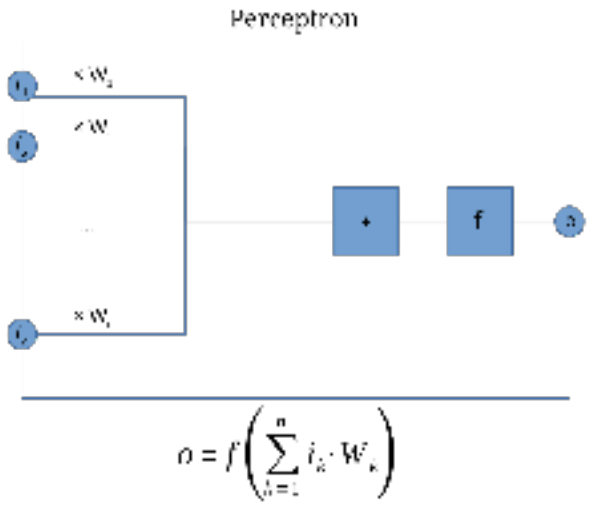

Schéma du perceptron
Source : Wikimedia Commons

- Auteur :
  - Frank Rosenblatt (1957).
- Principe :
  - combinaison linéaire des entrées,
  - décision par seuil.
- Importance :
  - premier modèle inspiré du neurone,
  - apprentissage automatique des poids.

Mots-clés : neurone artificiel, classification, apprentissage

Limites du perceptron et premier hiver de l'IA

1969 – années 1970

-40k -10k -3k 1450 1950 1990

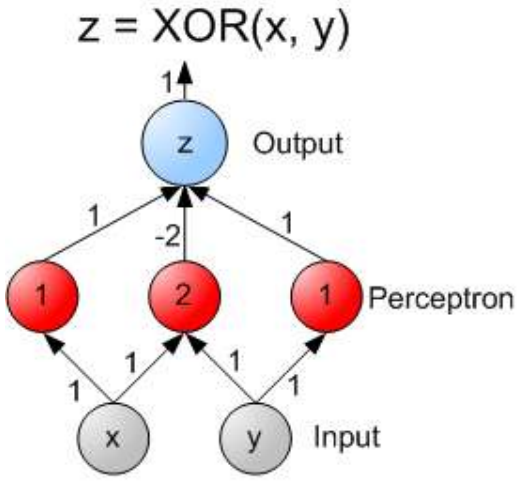

Problème XOR non séparable linéairement
Source : Wikimedia Commons

- Limite fondamentale :
  - le perceptron ne sépare que des données linéaires.
- Conséquence :
  - incapacité à résoudre des problèmes simples (ex. XOR).
- Impact historique :
  - forte baisse d'intérêt et de financements,
  - premier « hiver de l'IA ».

Mots-clés : limites, séparabilité, hiver de l'IA

Qu'est-ce qu'un hiver de l'IA ?

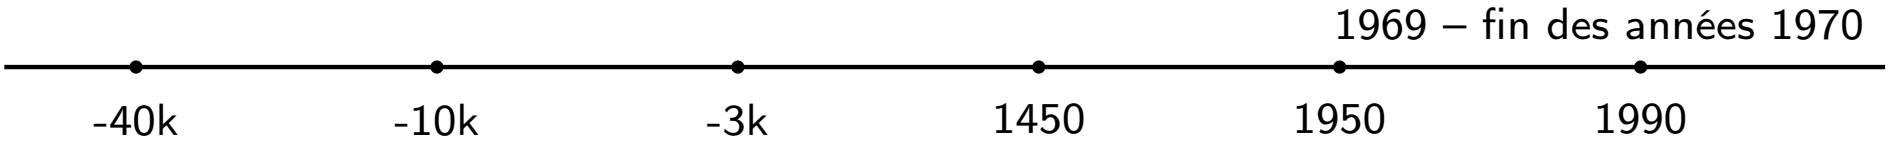

- Contexte :
  - fortes attentes autour de l'intelligence artificielle,
  - promesses rapides de machines "intelligentes".
- Réalité :
  - modèles trop simples (ex. perceptron),
  - manque de données et de puissance de calcul.
- Conséquences :
  - baisse des financements et de l'intérêt,
  - ralentissement de la recherche.

Un second hiver de l'IA

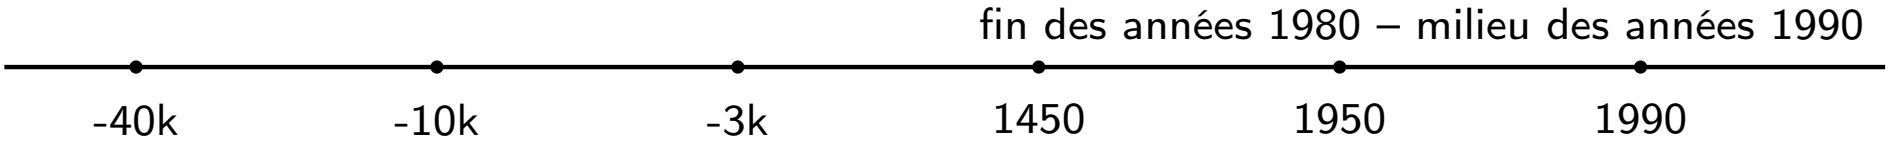

- Contexte :
  - succès des systèmes experts,
  - retour des réseaux neuronaux.
- Limites :
  - systèmes coûteux et fragiles,
  - manque de données et de calcul.
- Conséquences :
  - retrait des financements,
  - baisse de l'intérêt industriel.

Apprendre sans exemples annotés

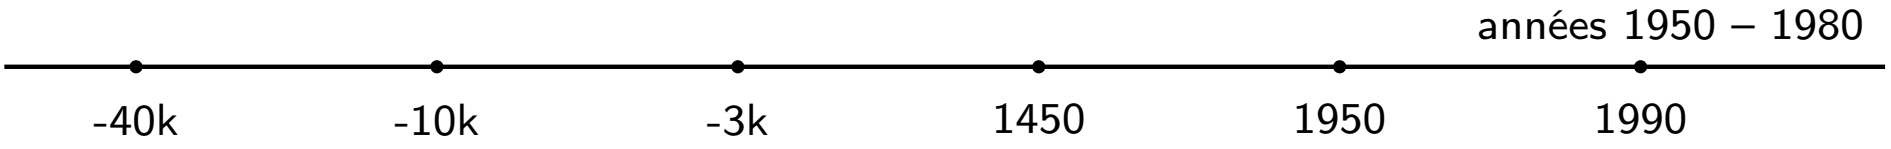

Et si l'on ne savait pas à l'avance
quelles sont les bonnes réponses ?

Découvrir la structure des données

Clustering : regrouper par similarité

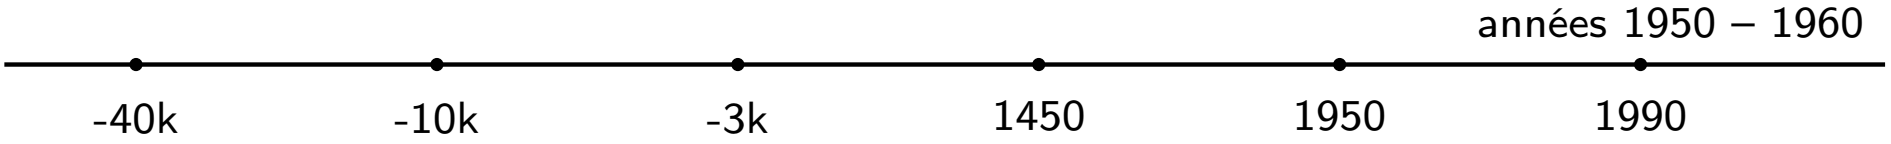

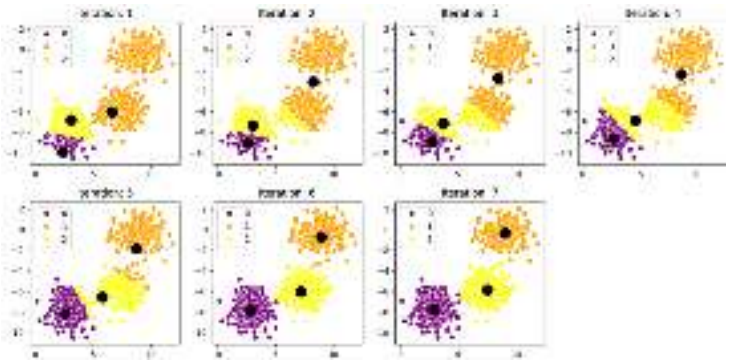

Principe de l'algorithme k-means
Source : GeeksforGeeks

- Objectif :
  - regrouper des données similaires,
  - sans information de classe.
- Principe :
  - définition de centres,
  - minimisation des distances intra-groupes.
- Usage :
  - exploration,
  - segmentation,
  - pré-traitement.

Mots-clés : similarité, distance, regroupement

Clustering hiérarchique

années 1960 – 1970

-40k -10k -3k 1450 1950 1990

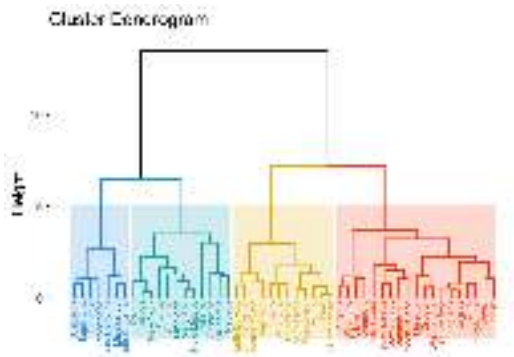

Exemple de dendrogramme
Source : Datanovia

- Principe :
  - regrouper progressivement les données,
  - construction d'une hiérarchie.
- Atout :
  - pas besoin de fixer le nombre de groupes,
  - visualisation globale de la structure.

Mots-clés : hiérarchie, structure, visualisation

Fouille de données : découvrir des relations

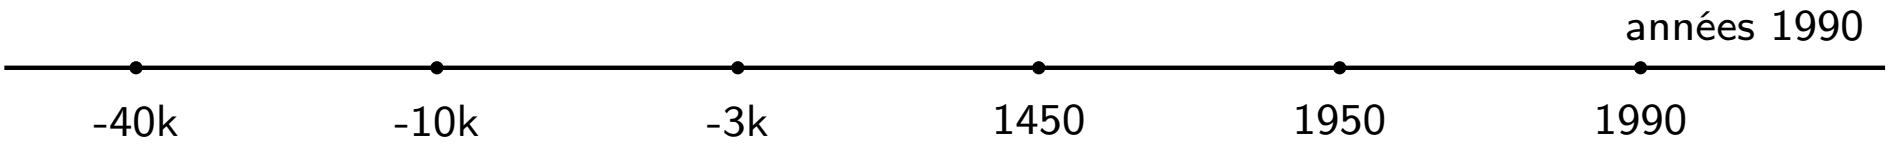

Quand les données deviennent massives,
le défi n'est plus seulement de regrouper...

...mais de détecter des relations cachées.

Règles d'association : découvrir des co-occurrences

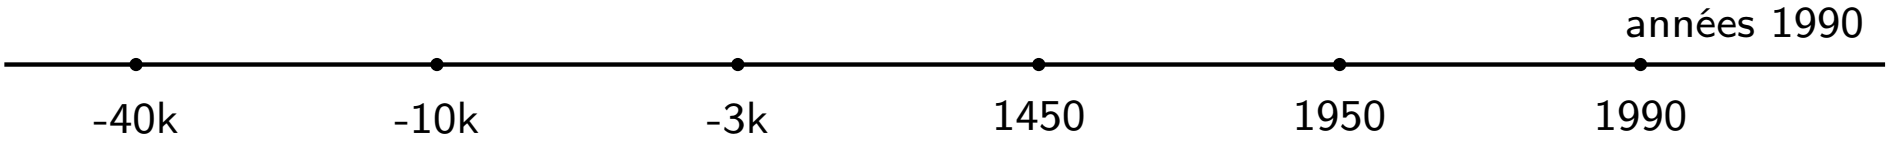

Analyse de paniers d'achat
Source : Wikimedia Commons

- Objectif :
  - trouver des relations fréquentes entre items.
- Forme :
  - `Si A alors B`.
- Mesures :
  - support, confiance, lift.

Mots-clés : co-occurrence, règles, fréquence

Apriori : extraire des règles pertinentes

1994

-40k -10k -3k 1450 1950 1990

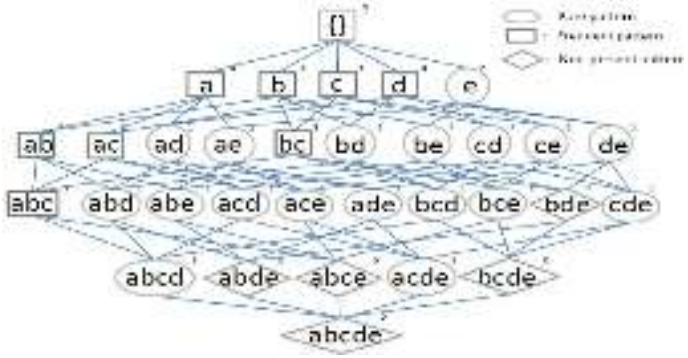

Treillis des itemsets fréquents
Source : Wikimedia Commons

- Principe :
  - exploration progressive des itemsets fréquents.
- Atout :
  - réduction drastique de l'espace de recherche.
- Usage :
  - recommandation,
  - analyse de comportements.

Mots-clés : itemsets, règles, fouille

k-plus proches voisins : apprendre par similarité

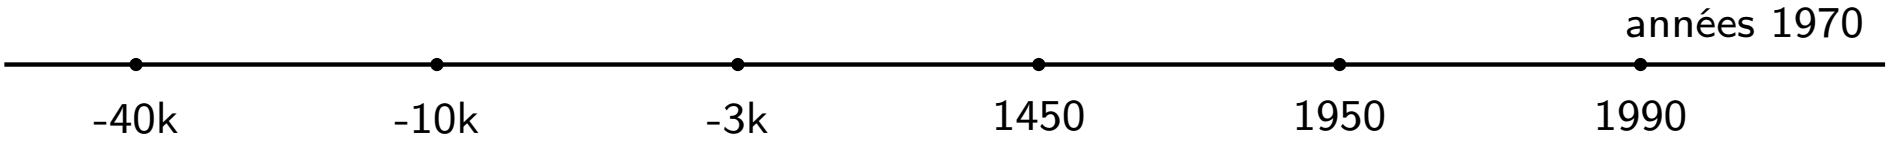

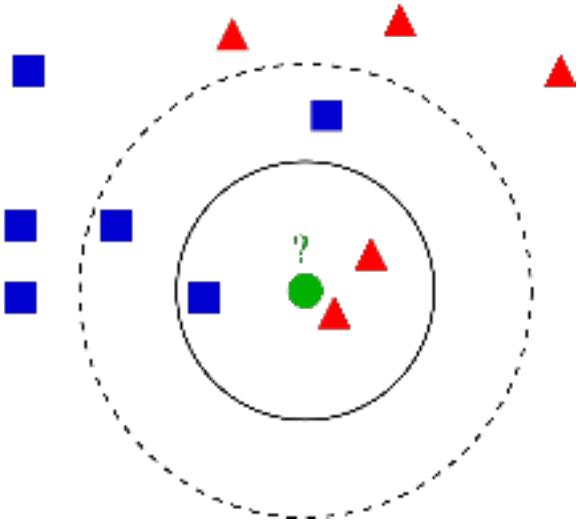

Principe du classifieur k-plus proches voisins
Source : Wikimedia Commons

- Idée :
  - similarité ⇒ même décision.
- Principe :
  - vote des voisins proches,
  - pas d'apprentissage explicite.
- Intérêt :
  - simple,
  - non paramétrique.

Mots-clés : similarité, distance, non paramétrique

Naive Bayes : apprendre avec les probabilités

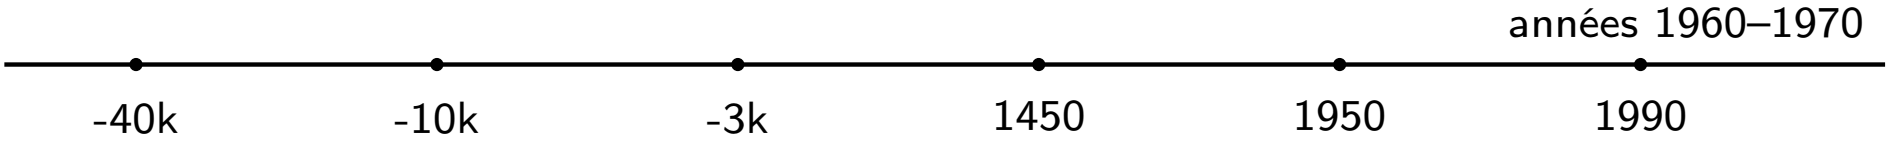

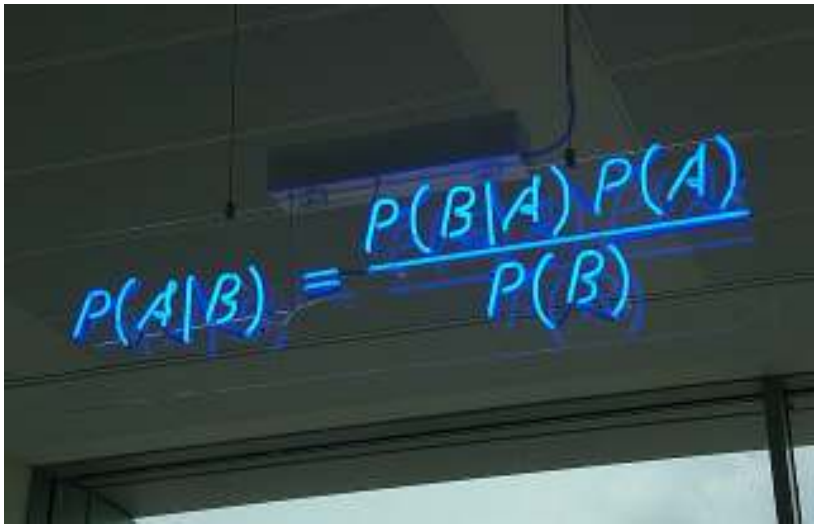

Principe du classifieur Naive Bayes
Source : Wikimedia Commons

- Origines :
  - théorème de Bayes (XVIIIe siècle),
  - formalisations modernes au XXe siècle.
- Principe :
  - modélisation probabiliste des classes,
  - hypothèse d'indépendance conditionnelle.
- Intérêt :
  - rapide, efficace en pratique (texte).

Mots-clés : probabilités, indépendance, classification

SVM : apprendre avec une marge maximale

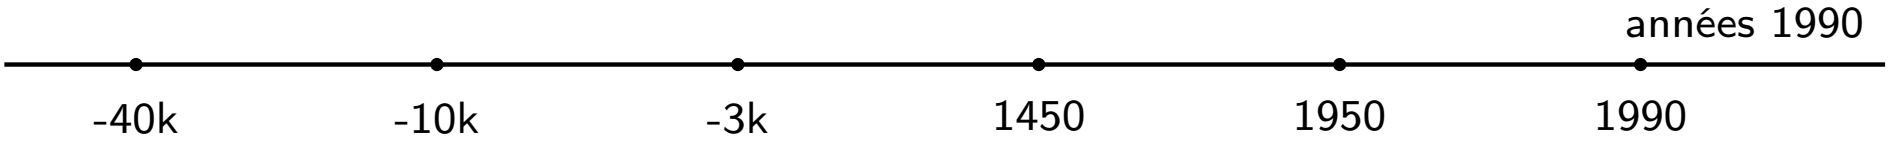

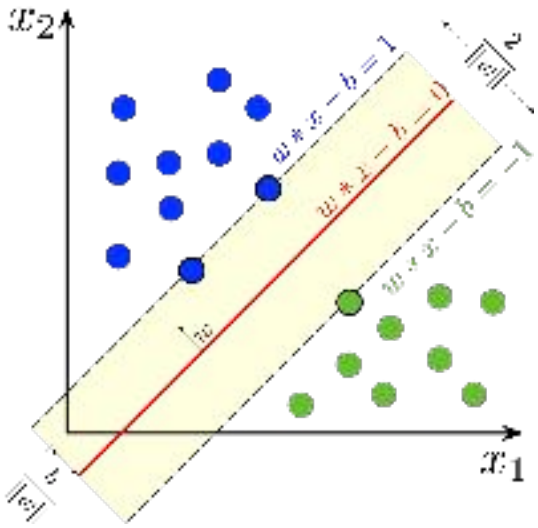

Principe de la marge maximale (SVM)
Source : Wikimedia Commons

- Auteur :
  - Vladimir Vapnik.
- Principe :
  - séparation linéaire optimale,
  - maximisation de la marge.
- Apport majeur :
  - bonne généralisation,
  - fondements théoriques solides.

Mots-clés : marge, généralisation, apprentissage statistique

Méthodes ensemblistes : combiner plusieurs modèles

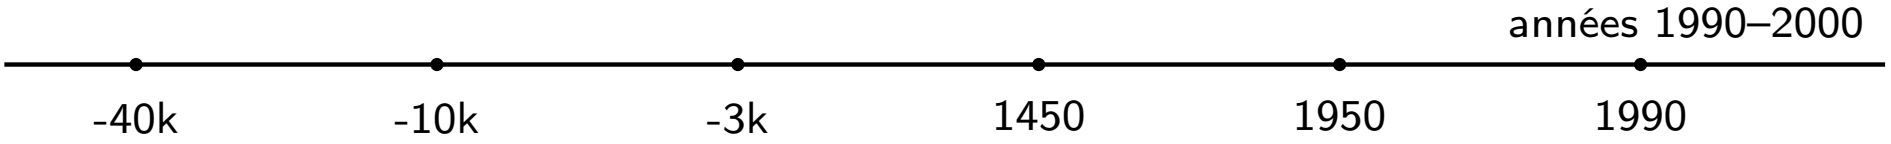

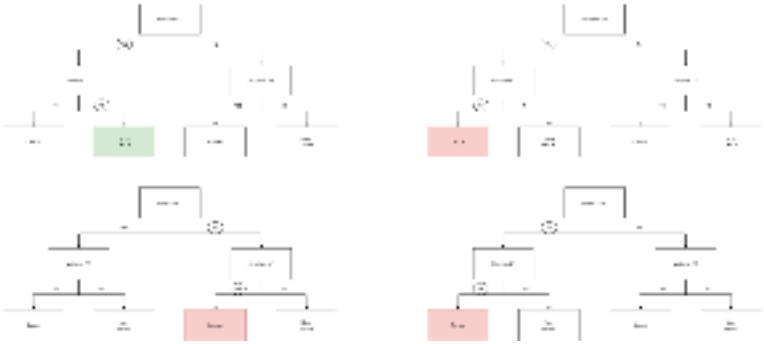

Principe d'un ensemble de modèles (Random Forest)
Source : Wikimedia Commons

- Idée centrale :
  - combiner plusieurs modèles simples.
- Exemples :
  - Bagging,
  - Random Forest (Breiman),
  - Boosting.
- Apport :
  - amélioration de la robustesse,
  - réduction de la variance.

Mots-clés : ensemble, robustesse, généralisation

Panorama des approches en apprentissage automatique

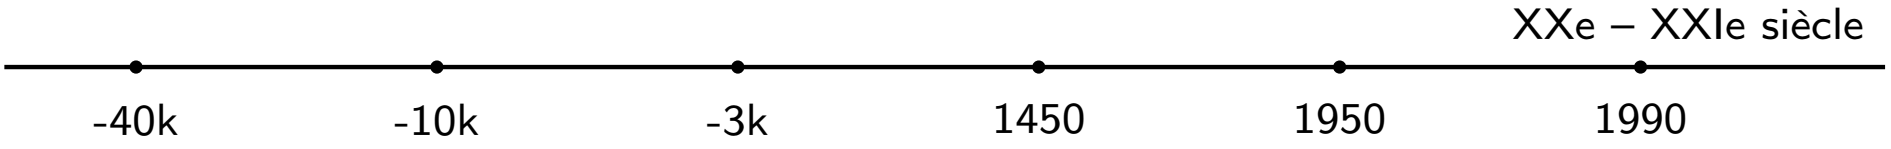

- Apprentissage supervisé :
  - données annotées,
  - objectif : prédire une sortie,
  - exemples : régression, SVM, réseaux de neurones.
- Apprentissage non supervisé :
  - données non annotées,
  - objectif : révéler la structure des données,
  - exemples : clustering, réduction de dimension.
- Fouille de données :
  - données souvent massives,
  - objectif : extraire des relations interprétables,
  - exemples : règles d'association, motifs fréquents.

Changer d'échelle : apprentissage profond

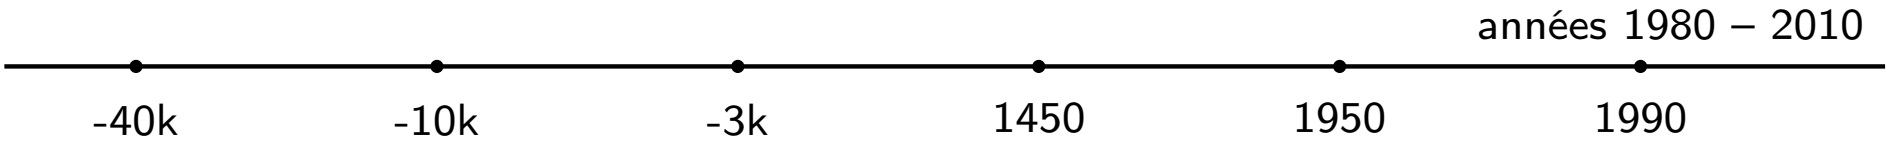

Toutes ces approches existent déjà ...

...mais une idée va leur permettre de changer d'échelle.

Backpropagation : apprendre des réseaux profonds

1986 – années 2010

-40k -10k -3k 1450 1950 1990

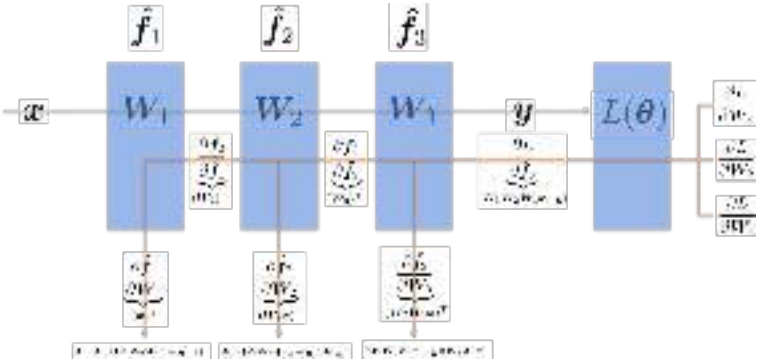

Rétropropagation du gradient
Source : Wikimedia Commons

- Idée :
  - apprendre les poids d'un réseau multi-couches.
- Mécanisme :
  - calcul du gradient,
  - mise à jour itérative des poids.
- Impact :
  - rend possible le Deep Learning moderne.

Mots-clés : gradient, entraînement, Deep Learning

2012 : AlexNet et l'explosion du Deep Learning

2012

-40k -10k -3k 1450 1950 1990

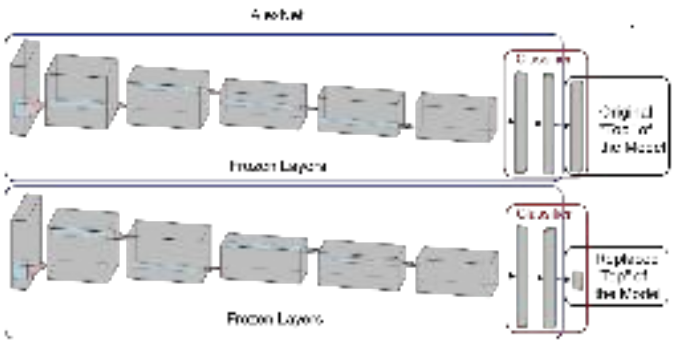

Architecture du réseau AlexNet
Source : Wikimedia Commons

- Contexte :
  - compétition ImageNet (vision par ordinateur).
- Rupture :
  - réseau profond convolutif,
  - entraîné sur GPU.
- Impact :
  - performances spectaculaires,
  - adoption massive du Deep Learning.

Mots-clés : réseaux convolutifs, GPU, ImageNet

2012–2015 : les CNN s'imposent

2012 – 2015

-40k -10k -3k 1450 1950 1990

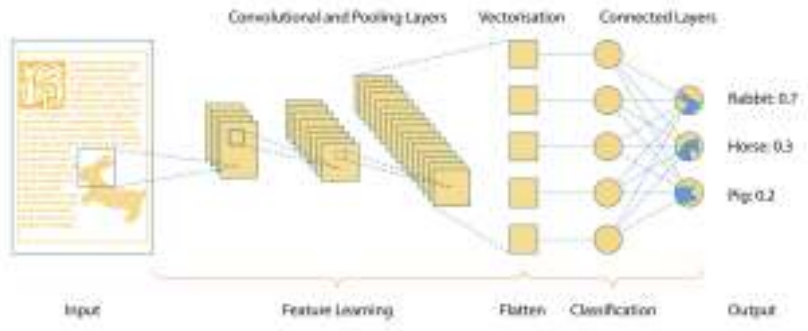

Principe d'un réseau convolutif (CNN)
Source : Wikimedia Commons

- Généralisation :
  - vision par ordinateur,
  - reconnaissance d'images.
- Atouts :
  - extraction automatique de caractéristiques,
  - invariance locale.
- Effet :
  - remplacement des approches manuelles,
  - standard industriel.

Mots-clés : convolution, vision, apprentissage

Apprendre une représentation

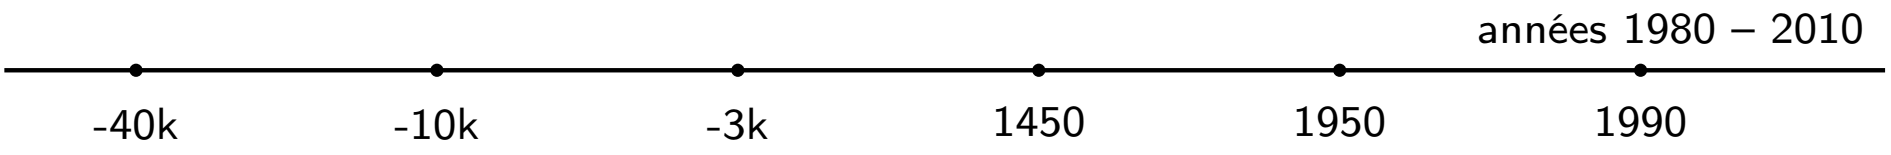

Avant de prédire ou de générer,
les modèles apprennent à représenter les données.

Autoencoders : apprendre une représentation

années 1980 – 2000

-40k -10k -3k 1450 1950 1990

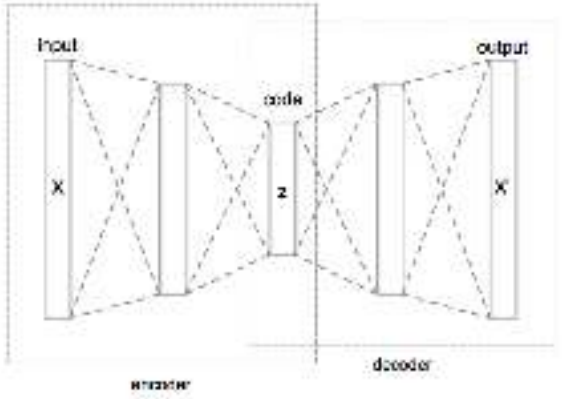

Architecture encodeur–décodeur
Source : Wikimedia Commons

- Objectif :
  - apprendre une représentation compacte des données.
- Principe :
  - encoder puis reconstruire l'entrée.
- Intérêt :
  - réduction de dimension,
  - extraction de caractéristiques.

Mots-clés : encodage, reconstruction, espace latent

Variational Autoencoders (VAE)

2013

-40k -10k -3k 1450 1950 1990

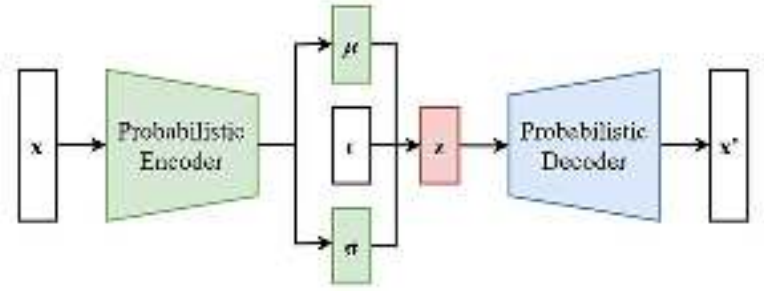

Autoencodeur variationnel
Source : Wikimedia Commons

- Extension probabiliste des autoencoders.
- Apprentissage d'un espace latent continu.
- Possibilité de générer de nouvelles données.

Mots-clés : probabilités, génération, latent continu

GAN : générer par confrontation

2014

-40k -10k -3k 1450 1950 1990

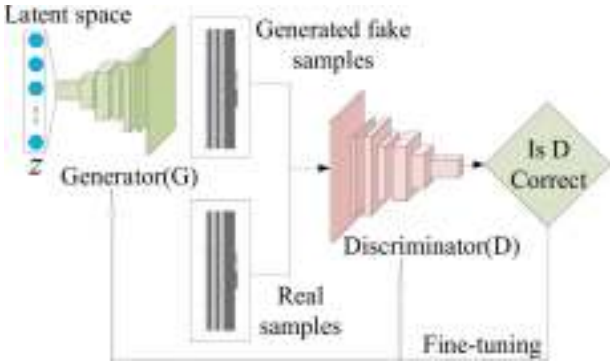

Générateur et discriminateur
Source : Labellerr

- Deux réseaux en compétition :
  - générateur,
  - discriminateur.
- Apprentissage adversarial.
- Génération de données réalistes.

Mots-clés : adversarial, compétition, génération

Modèles de diffusion : générer par débruitage

2020 – 2022

-40k -10k -3k 1450 1950 1990

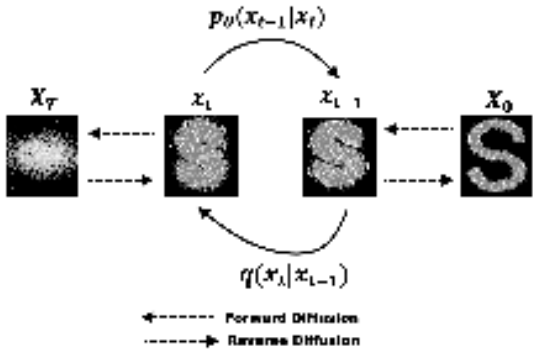

Processus de diffusion et débruitage
Source : Towards Data Science

- Ajout progressif de bruit aux données.
- Apprentissage du processus inverse.
- Génération stable et contrôlable.

Mots-clés : bruit, débruitage, génération

Même idée, autre type de données

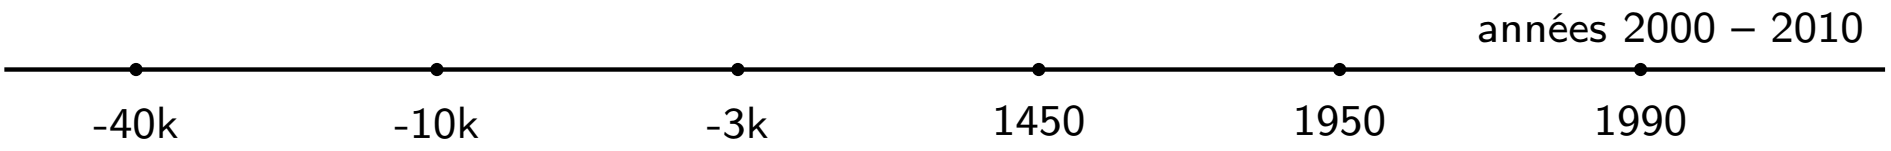

Dans les images, nous avons appris :

un espace latent continu

Pour le texte, le défi est le même :

passer de symboles à des vecteurs

Pourquoi les embeddings sont nécessaires

années 2000 – 2010

-40k -10k -3k 1450 1950 1990

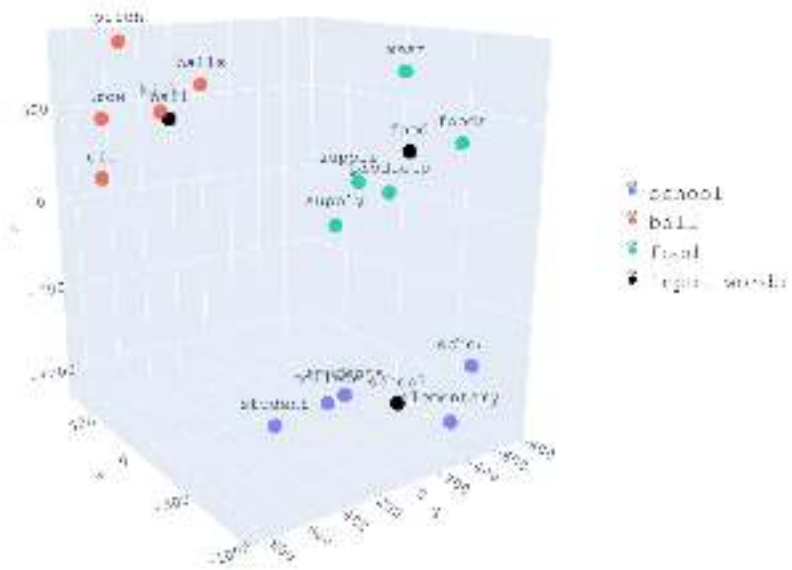

Projection d'embeddings de mots dans un espace vectoriel
Source : Towards Data Science

- Problème :
  - mots = symboles discrets,
  - réseaux = nombres réels.
- Limite des encodages simples :
  - one-hot : aucune similarité.
- Embeddings :
  - vecteurs continus,
  - proximité ≈ sens.

Mots-clés : représentation, continuité, similarité

Word2Vec : apprendre des représentations sémantiques

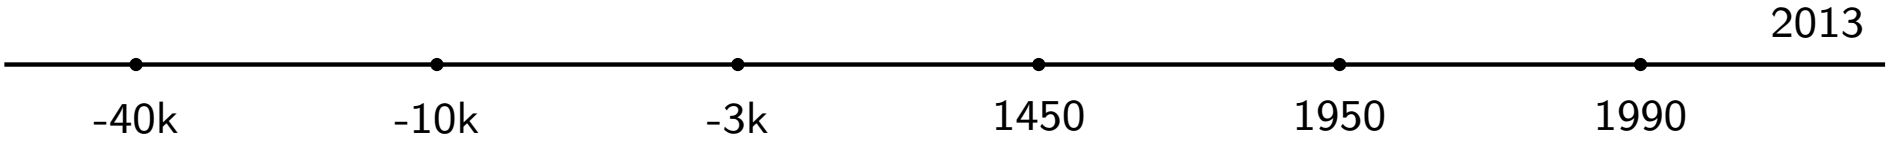

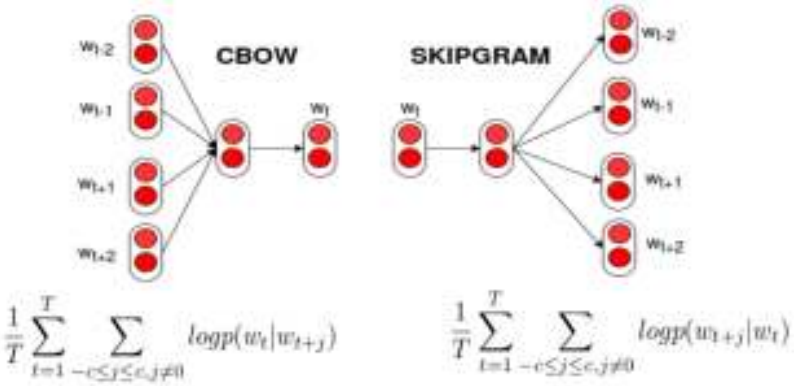

Principe du modèle Skip-gram (Word2Vec)
Source : Wikimedia Commons

- Auteurs :
  - Tomas Mikolov et al. (Google, 2013).
- Principe :
  - apprendre à prédire un mot à partir de son contexte,
  - sans annotation manuelle.
- Résultat :
  - un mot devient un vecteur dense,
  - proximité vectorielle $\approx$ proximité sémantique.

Mots-clés : Word2Vec, contexte, représentation

Apprendre sur des données séquentielles

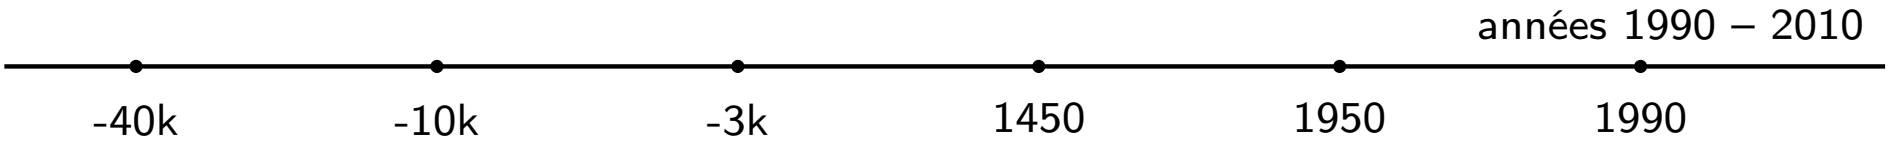

Et si les données avaient un ordre ?

Texte, séries temporelles, parole

RNN : les premiers réseaux pour les séquences

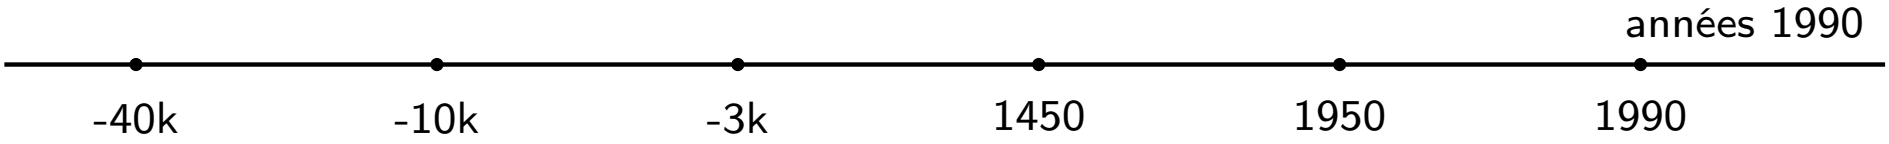

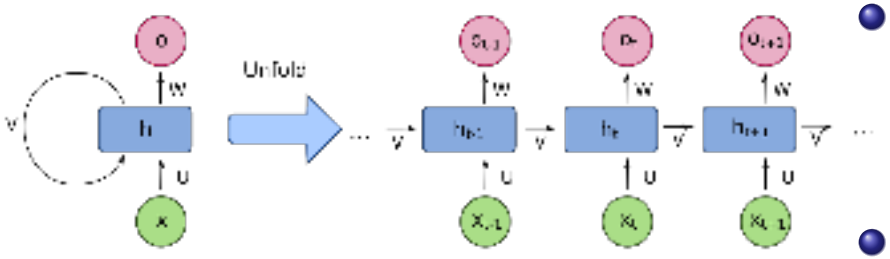

Dépliage temporel d'un réseau récurrent (RNN)
Source : Wikimedia Commons

- Principe :
  - traiter une séquence,
  - conserver un état interne.
- Limite :
  - gradients instables,
  - mémoire limitée.

Mots-clés : récurrence, état caché

LSTM : mémoriser sur le long terme

1997

-40k -10k -3k 1450 1950 1990

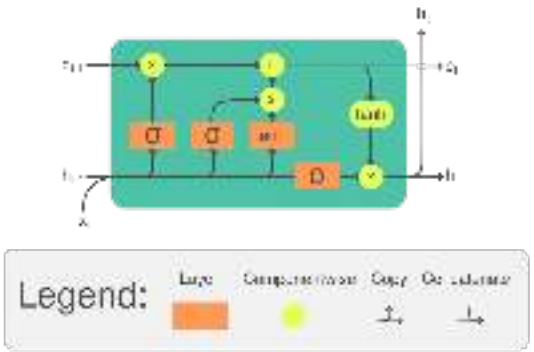

Cellule LSTM
Source : Wikimedia Commons

- Auteurs :
  - Hochreiter & Schmidhuber (1997).
- Problème traité :
  - dépendances longues,
  - gradients instables.
- Idée clé :
  - mémoire contrôlée par des portes.

Mots-clés : mémoire, séquences, récurrence

Pourquoi dépasser les LSTM ?

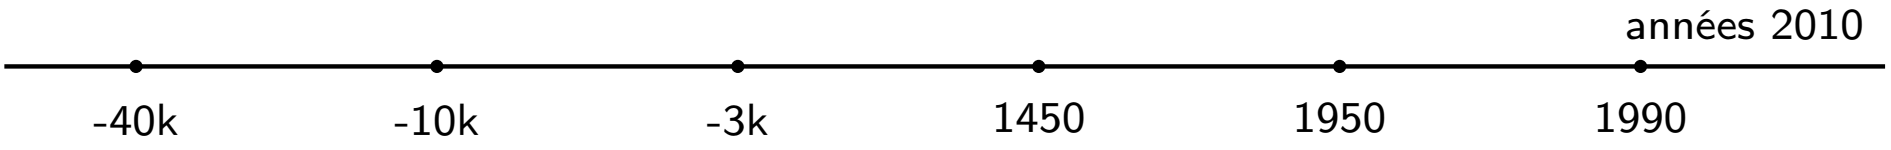

Les LSTM apprennent des séquences ...

...mais restent séquentiels et difficiles à paralléliser.

Attention : se concentrer sur l'essentiel

2014

-40k -10k -3k 1450 1950 1990

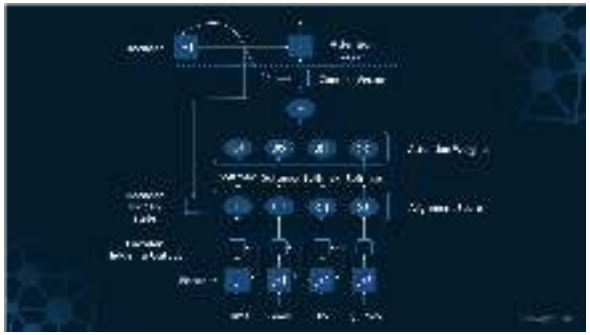

Principe du mécanisme d'attention
Source : Wikimedia Commons

- Idée clé :
  - pondérer les éléments pertinents d'une séquence.
- Avantage :
  - accès direct à l'ensemble de la séquence,
  - meilleures dépendances longues.
- Usage initial :
  - traduction automatique,
  - modèles encodeur–décodeur.

Mots-clés : pondération, dépendances, séquences

2017 : *Attention is All You Need*

2017

-40k -10k -3k 1450 1950 1990

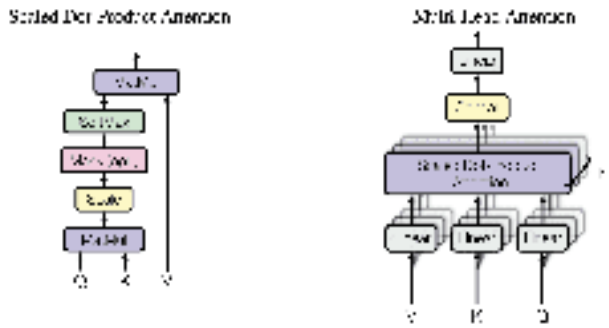

Attention à produit scalaire normalisé
Source : Wikimedia Commons

- Rupture :
  - plus de récurrence,
  - architecture entièrement basée sur l'attention.
- Conséquences :
  - parallélisation massive,
  - entraînement à grande échelle.
- Héritage :
  - Transformers,
  - modèles de langage modernes.

Mots-clés : transformer, parallélisation, échelle

Le Transformer : une nouvelle architecture

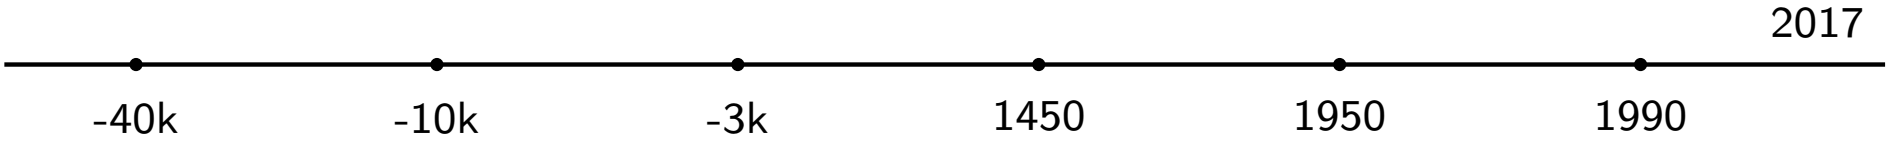

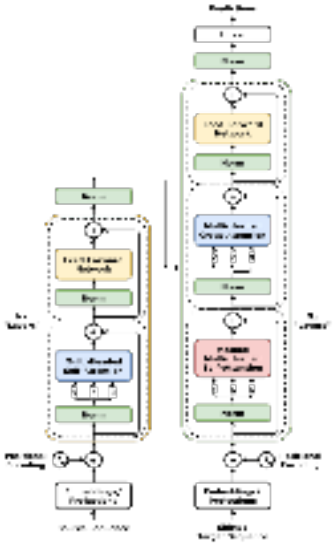

Architecture encodeur–décodeur Transformer
Source : Wikimedia Commons

- Architecture basée sur l'attention
- Traitement parallèle des séquences
- Base des modèles modernes

Mots-clés : architecture, attention, parallélisation

Des architectures aux modèles de langage

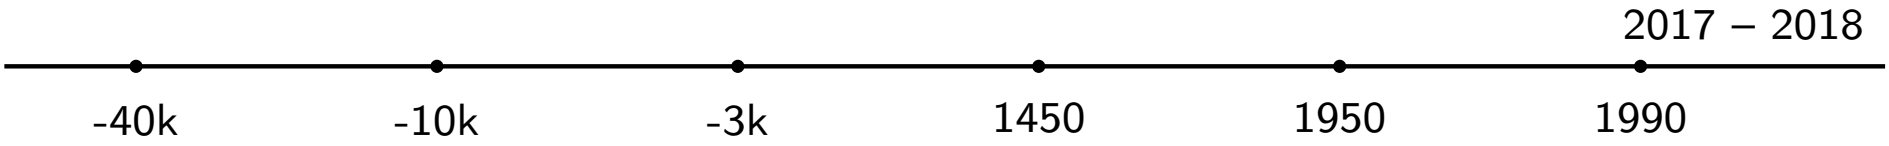

Le Transformer n'est qu'une architecture.

La question devient alors :

Que peut-on apprendre avec de très grands corpus ?

BERT : comprendre le langage par le contexte

2018

-40k -10k -3k 1450 1950 1990

Architecture du modèle BERT
Source : Towards Data Science

- Auteurs :
  - Devlin et al. (Google).
- Idée clé :
  - apprentissage bidirectionnel,
  - compréhension du contexte global.
- Apport :
  - amélioration massive des tâches NLP,
  - standard de fait en NLP.

Mots-clés : contexte, bidirectionnalité, compréhension

GPT : générer du langage

2018 – 2020

-40k -10k -3k 1450 1950 1990

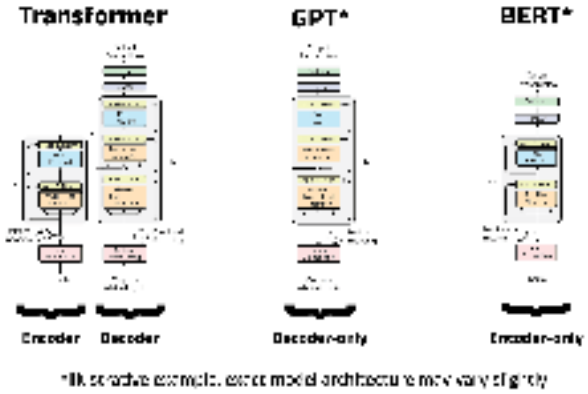

Transformer de type décodeur (GPT)
Source : Towards Data Science

- Principe :
  - prédire le mot suivant,
  - apprentissage auto-supervisé.
- Différence avec BERT :
  - génération au lieu de compréhension.
- Conséquence :
  - modèles capables de produire du texte cohérent.

Mots-clés : génération, autoregressif, langage

LLM : quand l'échelle change tout

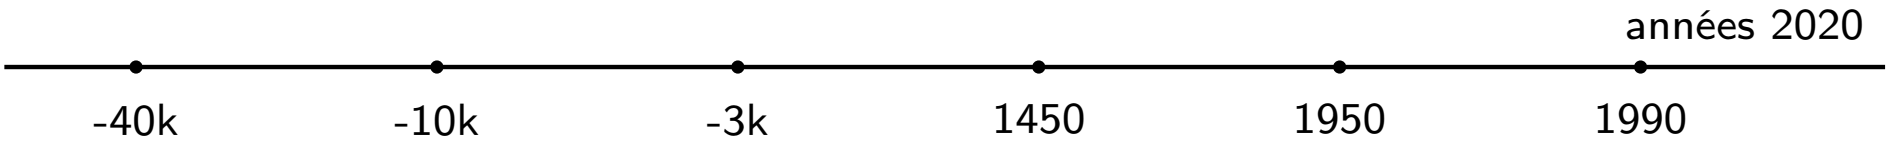

Même architecture.

Beaucoup plus de données.

Beaucoup plus de paramètres.

Des comportements émergents

Pourquoi ces modèles fonctionnent “trop bien” ?

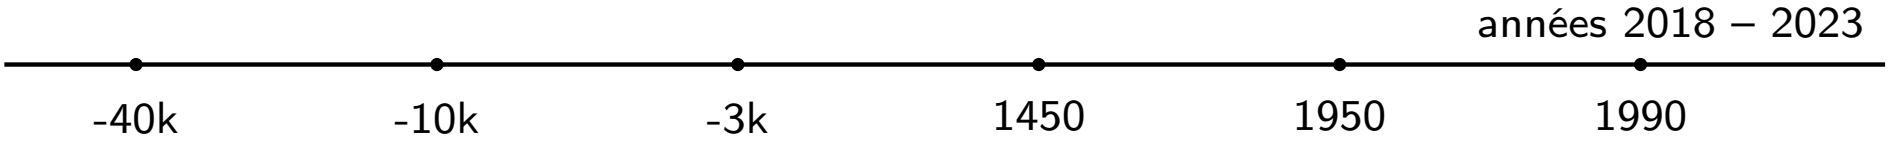

- Même principe fondamental :
  - prédire le prochain élément (mot, pixel, token).
- Trois facteurs clés :
  - architectures efficaces (Transformers),
  - volumes massifs de données,
  - optimisation à grande échelle (GPU/TPU).
- Résultat :
  - comportements émergents (pas été programmé explicitement pour),
  - généralisation inattendue (réussir sur des situations jamais vues).

Mots-clés : échelle, émergence, généralisation

L'effet de l'échelle

2018 – aujourd'hui

-40k -10k -3k 1450 1950 1990

Modèle	Année	Paramètres
BERT-base	2018	110 M
GPT-2	2019	1.5 B
GPT-3	2020	175 B
GPT-4	2023	$\sim 10^{11}$–10^{12} (estimé)
DALL·E 2	2022	$\sim$3.5 B
Stable Diffusion	2022	$\sim$860 M

Ordres de grandeur — chiffres publics ou estimations

Des questions ?