Données, modèles et usages

Limites et responsabilités

Université de Montpellier – LIRMM

HAI817I

Pascal Poncelet
Pascal.Poncelet@lirmm.fr
http://www.lirmm.fr/~poncelet

Plan

1. Du bon usage des données
2. Réseaux sociaux : ce qu'il y a derrière
3. CNIL, RGPD et protection des données
4. Grands modèles de langage : usages, limites, impacts
5. Bon usage des LLM : méthodes et réflexes

Plan

1. Du bon usage des données
2. Réseaux sociaux : ce qu'il y a derrière
3. CNIL, RGPD et protection des données
4. Grands modèles de langage : usages, limites, impacts
5. Bon usage des LLM : méthodes et réflexes

Avant les modèles

Toute intelligence artificielle commence par des données.

Et les données ne sont jamais neutres.

Première question

Est-ce que j'ai le droit d'utiliser ces données ?

Technique $\neq$ Autorisation

Ce qui a changé

- Les données viennent de sources multiples
- Les croisements sont faciles (data linking)
- On peut retrouver une personne sans son nom

Deux exemples de croisement

- **Logs de recherche (AOL, 2006)** :
  - un identifiant “anonyme” + des requêtes suffisent
  - la personne peut être retrouvée par recoupement

- **Santé (Sweeney, 1997)** :
  - données médicales publiées + liste électorale
  - appariement via code postal + date de naissance + sexe

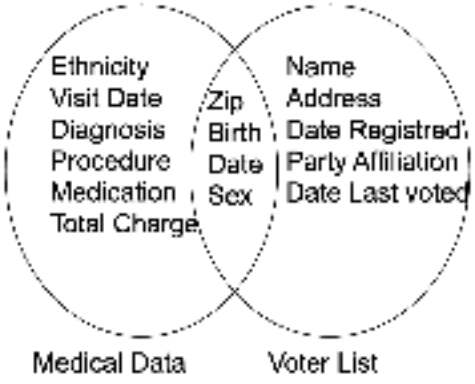

Le risque vient souvent du recoupement, pas d’une colonne “nom” !

Deuxième mécanisme : l'agrégation

Une donnée banale peut devenir problématique par agrégation.

- On ne vise pas une personne, mais un groupe
- On résume, on segmente, on profile
- Les décisions deviennent statistiques, mais réelles

Même sans ré-identifier, on peut discriminer ou cibler !

Agrégation : exemples simples

- Mobilité + horaires = routines et zones d'activité
- Achats + fréquence = profils de consommation
- Contenus consultés + temps passé = centres d'intérêt

Ici, le but n'est pas d'identifier : c'est de classer.

Agrégation : exemples plus sensibles

- Même sans déclarer une information,
- un modèle peut l'inférer :
  - état de santé ou fragilité,
  - situation financière,
  - opinions ou sensibilités,
  - vulnérabilités (ciblage, manipulation).

Le risque vient souvent des inférences, pas de la colonne d'origine !

Conséquence

Classer un profil peut suffire
à prendre une décision sur une personne.

Ce que vous révélez sans le savoir

3–4 signaux "banals"

- historique de recherche
- géolocalisation (même grossière)
- heures de connexion / activité
- achats (catégories)

Ce qu'on peut déduire (souvent)

- domicile + travail + trajets
- entourage (relations, habitudes)
- état de santé (visites, centres, thèmes)
- grossesse / parentalité (signaux d'achat)
- fragilités (addiction, stress, isolement)

Ce n'est pas l'info isolée qui est "dangereuse" : c'est le recoupement !

Navigation web : une collecte massive et souvent invisible

- Pages consultées, recherches, clics, temps passé
- Adresse IP, appareil, navigateur, langue, fuseau horaire
- Cookies et identifiants publicitaires
- Traceurs tiers : pubs, analytics, boutons “partager”
- Recoupements possibles entre sites et sessions

Sur le web, la navigation produit des données en continu !

Navigation web : volume collecté & valeur marchande

- **Sur une page web :** beaucoup d'acteurs tiers peuvent intervenir
  - médiane : ~27 tiers / page (top 1M sites)
  - médiane : ~66 tiers / page (top 1k sites)
  - certains bandeaux cookies affichent >1 500 *partners* (publicité / mesure)

- **Sur le marché :** un profil peut coûter très peu (exemples)
  - âge + genre + localisation : ~$0.0005 / personne
  - dans beaucoup de cas : <$1 / personne (ordre de grandeur)

Sources : Web Almanac (HTTP Archive), 2024 Third Parties ; WIRED, Cookie pop-ups & 1,500+ partners ; Financial Times, How much is your personal data worth?.

Plan

1. Du bon usage des données
2. Réseaux sociaux : ce qu'il y a derrière
3. CNIL, RGPD et protection des données
4. Grands modèles de langage : usages, limites, impacts
5. Bon usage des LLM : méthodes et réflexes

Réseaux sociaux : pourquoi ça marche

- Se connecter, partager, apprendre
- Découvrir des communautés et des contenus
- Organiser sa vie sociale (événements, messages, groupes)

Un super outil !

Source : Wikimedia Commons

Des volumes hors normes

- Monde : **5.66 milliards** d'"identités" actives (oct. 2025)
- France : **51.5 millions** d'identités actives (oct. 2025)
- Une "super-majorité" : la norme devient *d'être présent*

À cette échelle, l'effet d'une publication n'est plus local !

Source : Wikimedia Commons

Sources chiffres : DataReportal (Global, Oct 2025) ; DataReportal (France, Oct 2025).

Tout devient donnée sur une plateforme

- Publications, commentaires, partages
- Réactions : likes, favoris, abonnements
- Messages, groupes, invitations
- "Signaux faibles" : temps de visionnage, pauses, relectures

Le "contenu" est visible, les signaux le sont beaucoup moins !

Source : Wikimedia Commons

Un ami peut divulguer pour vous

- Photo de groupe : vous êtes dedans, même si vous ne postez rien
- Tag / mention : votre nom circule via d'autres comptes
- Partage en cascade : perte de contrôle de l'audience
- Captures d'écran : "privé" ne veut pas dire "confidentiel"

Source : Wikimedia Commons

Votre exposition dépend aussi du comportement des autres !

Demandes d'amis : une "attaque" très simple

- **Sophos (2007) – "Freddi Staur" (Facebook)**
  - 200 demandes envoyées, 87 acceptées
  - ~41% des personnes ciblées ont exposé des infos perso
- **Boshmaf et al. (2011) – socialbots (Facebook)**
  - phase 1 : 5 053 profils ciblés, taux d'acceptation moyen 19.3%
  - avec amis en commun : 54.6% en moyenne, jusqu'à 80%

Le "risque" vient souvent du lien social :
l'ami (réel ou faux) ouvre l'accès au profil.

Sources : The Register (Sophos, 2007), facebook_user_survey ; Kosta (PrimeLife 2009), Kosta09.pdf ; Boshmaf et al. (ACSAC 2011), acsac2011.pdf.

Fake news : un exemple très concret (2013)

- Compte `@AP` piraté : un faux tweet déclenche une panique
- Diffusion très rapide : plus de 4 000 retweets en moins de 5 minutes
- Effet immédiat : baisse brutale du Dow Jones (-143 points)
- Valeur effacée brièvement : ~136 Md$ puis correction

La viralité peut produire un effet réel avant toute vérification !

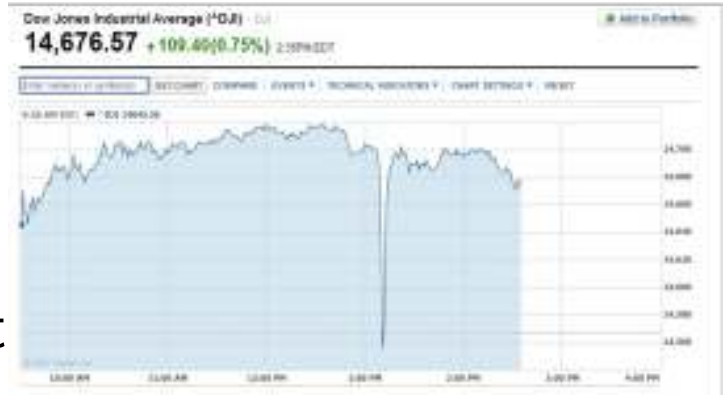

Source : The Associated Press / Dow Jones

Sources : ABC News (retweets), AP Twitter hacked ; Reuters via ABC Australia (136.5 Md$ en 3 min), Market chaos after fake tweet ; The Guardian (Dow Jones ~143 pts), AP tweet hack sends Dow plunging.

Fake news : pourquoi ça se propage

- Les algorithmes optimisent souvent l'engagement
- Le viral gagne sur le vérifié (court, émotionnel, polarisant)
- Avant de partager : source, date, image, intention

"Je le vois partout" n'est pas un critère de vérité !

Source : Wikimedia Commons

Violences numériques : du discret au massif

- Une attaque peut partir d'un message et devenir une action collective
- Doxxing : rendre publiques des informations privées
- Humiliation durable : copies, reposts, comptes "miroirs"

Source : Wikimedia Commons

Risques graves : manipulation et prédation

- Grooming (pédopiégeage) : mise en confiance progressive, isolement, pression
- Sextorsion : chantage à partir d'images / infos obtenues en ligne
- **Au cas où** : couper le contact, ne pas céder, garder les preuves, signaler

Source : Wikimedia Commons

Le danger n'est pas théorique : il vise des personnes réelles !

Pokémon GO : permissions et données (exemple grand public)

- Pour fonctionner, l'app demande typiquement :
  - localisation (jeu basé sur les déplacements),
  - caméra (mode AR, optionnel),
  - identifiants / appareil + télémétrie d'usage.
- 2016 (iOS) : une connexion Google demandait *par erreur* un accès trop large au compte (corrigé ensuite)
- Contexte : Niantic vient du monde Geo (Maps / Street View) ; les données de localisation ont une valeur et des risques propres

Source : Wikimedia Commons (CC0)

Plan

1. Du bon usage des données
2. Réseaux sociaux : ce qu'il y a derrière
3. CNIL, RGPD et protection des données
4. Grands modèles de langage : usages, limites, impacts
5. Bon usage des LLM : méthodes et réflexes

Pourquoi un cadre légal ?

- Les données circulent, se recoupent, se revendent
- Une information “banale” peut devenir personnelle
- Il faut des droits opposables et des responsabilités

Protéger les personnes, pas bloquer la techno !

Source : Wikimedia Commons

RGPD : l'idée centrale

- Définir une finalité claire (pourquoi ?)
- Collecter le minimum (vraiment utile)
- Informer, sécuriser, et rendre des comptes

Pas de "on collecte et on verra après" !

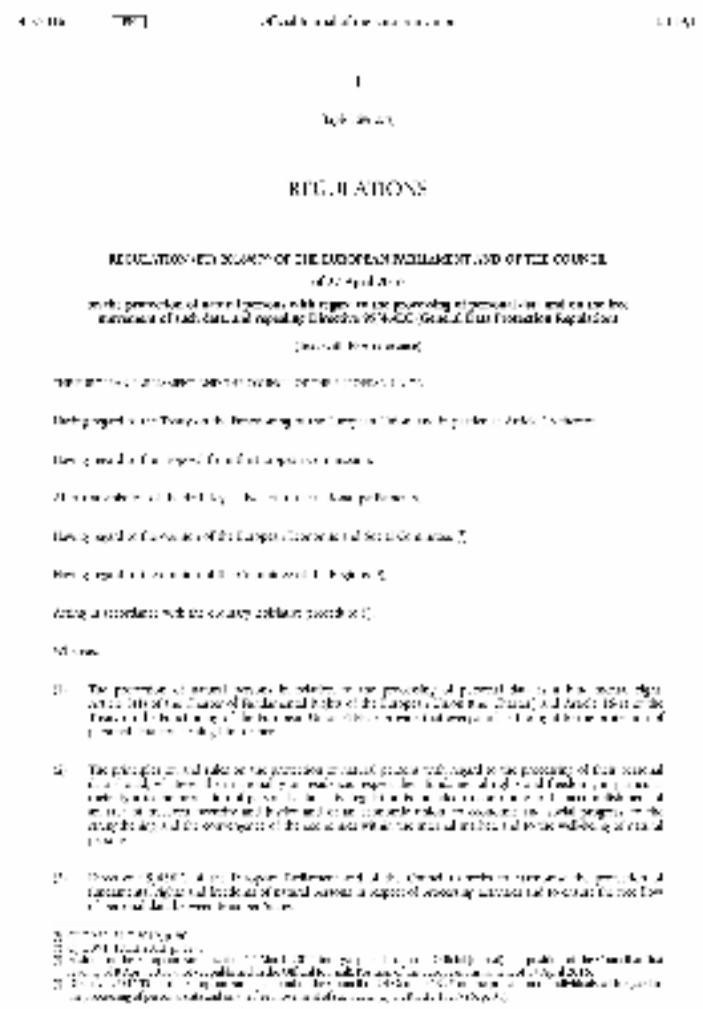
REGULATIONS

Source : Wikimedia Commons (Journal officiel UE)

RGPD : des droits concrets

- Accès, rectification, effacement
- Opposition, limitation, portabilité
- Information claire + recours (CNIL)

Un utilisateur peut demander : “qu’est-ce que vous savez sur moi ?”.

Source : Wikimedia Commons

DPIA (AIPD) : le réflexe avant de lancer un traitement

- "Data Protection Impact Assessment" : À faire pour les traitements à risque élevé (profilage, données sensibles, grande échelle, surveillance)
- On documente :
  - finalité, base légale, données, accès, durées
  - transferts, sous-traitants, sécurité
- On évalue les risques et les mesures de réduction
- Si le risque reste élevé : action avant mise en production

Source : Wikimedia Commons

Sources : CNIL (AIPD) ; RGPD, article 35.

Données de santé : un cas à part

- Données *sensibles* : diagnostic, traitements, examens
- Risque fort même sans nom : ré-identification, stigmatisation
- Accès restreint : traçabilité, accès aux données que strictement nécessaires
- Hébergement et sécurité : exigences renforcées (ex. HDS - Hébergement de Données de Santé (cadre/certification en France))

Source : Wikimedia Commons

Au-delà du légal : principes FAIR (recherche)

- **Findable** : métadonnées + identifiants (trouvable)
- **Accessible** : accès *maîtrisé* (contrôle, traçabilité)
- **Interoperable** : formats et standards (réutilisable ailleurs)
- **Reusable** : documentation, qualité, licences (réutilisable)

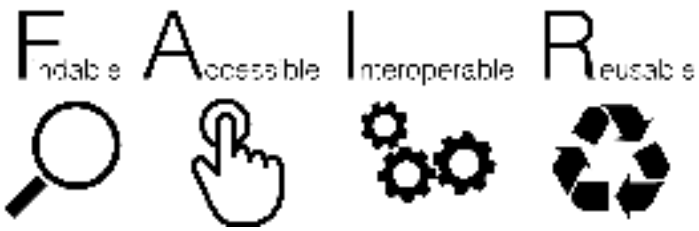

Source : Wikimedia Commons

FAIR ne veut pas dire “public”.
On peut être FAIR avec un accès restreint.

Réf. : Wilkinson et al., *The FAIR Guiding Principles for scientific data management and stewardship*, 2016.

Plan

1. Du bon usage des données
2. Réseaux sociaux : ce qu'il y a derrière
3. CNIL, RGPD et protection des données
4. Grands modèles de langage : usages, limites, impacts
5. Bon usage des LLM : méthodes et réflexes

Paysage open source (1/2)

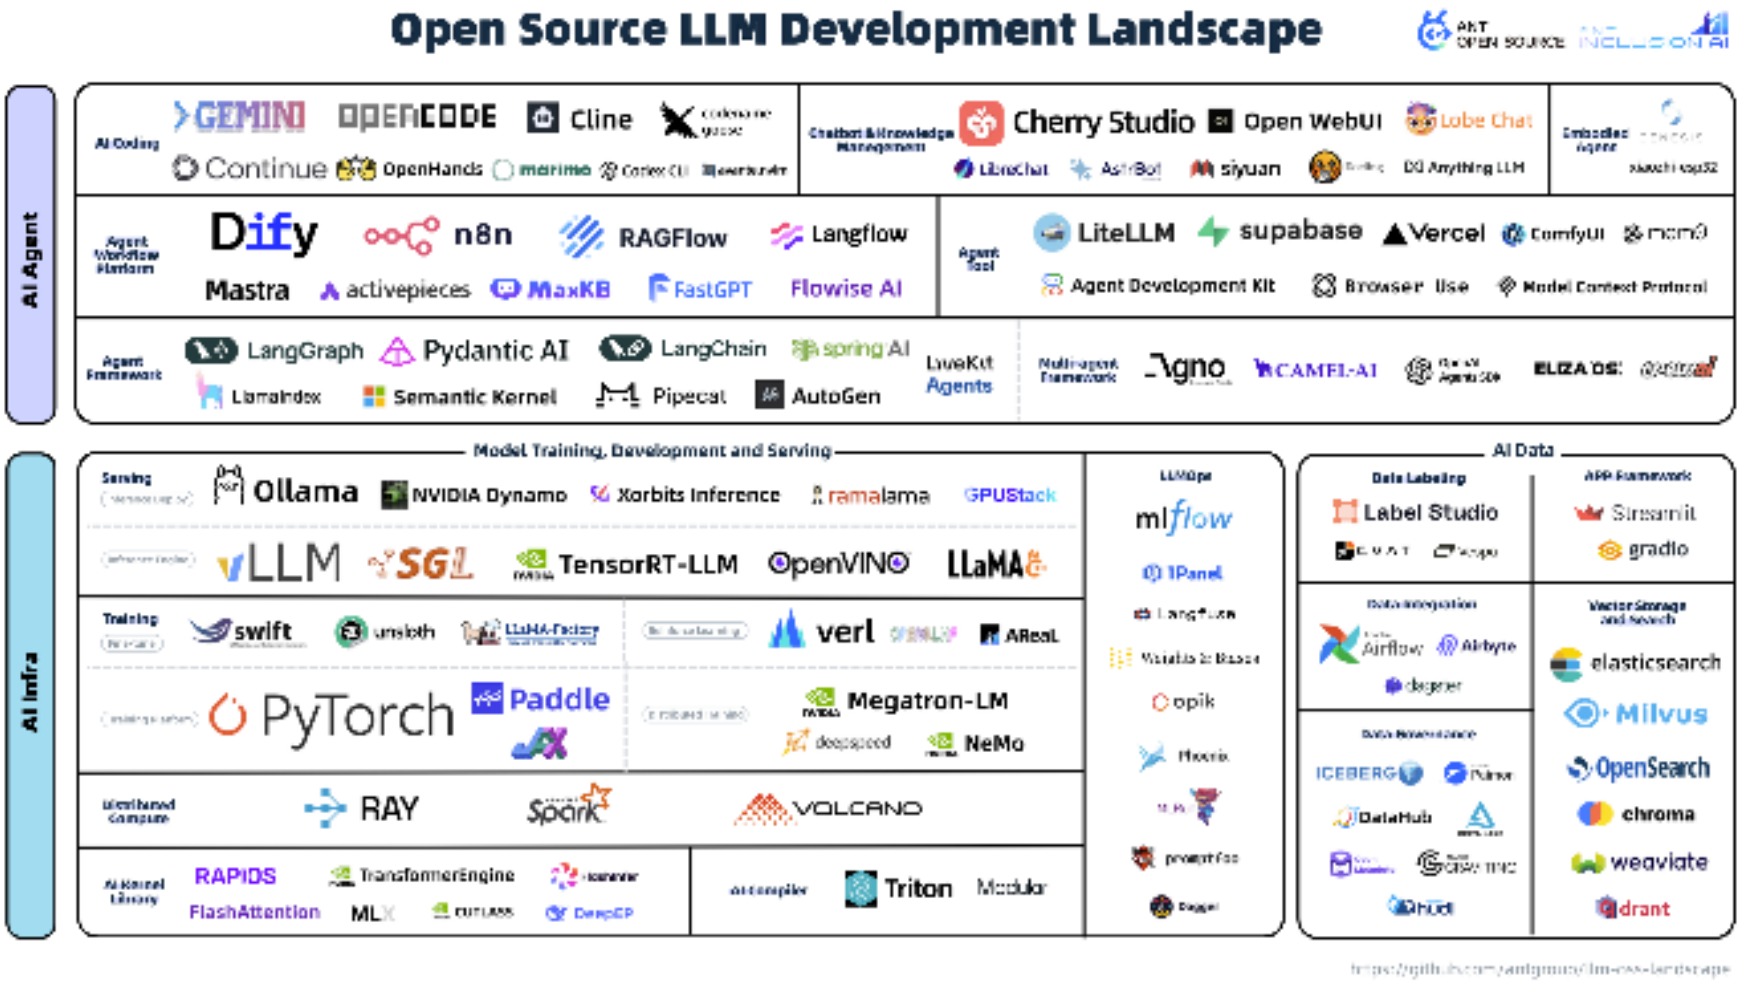

Source : Ant Open Source (© Ant Group)

Paysage open source (2/2)

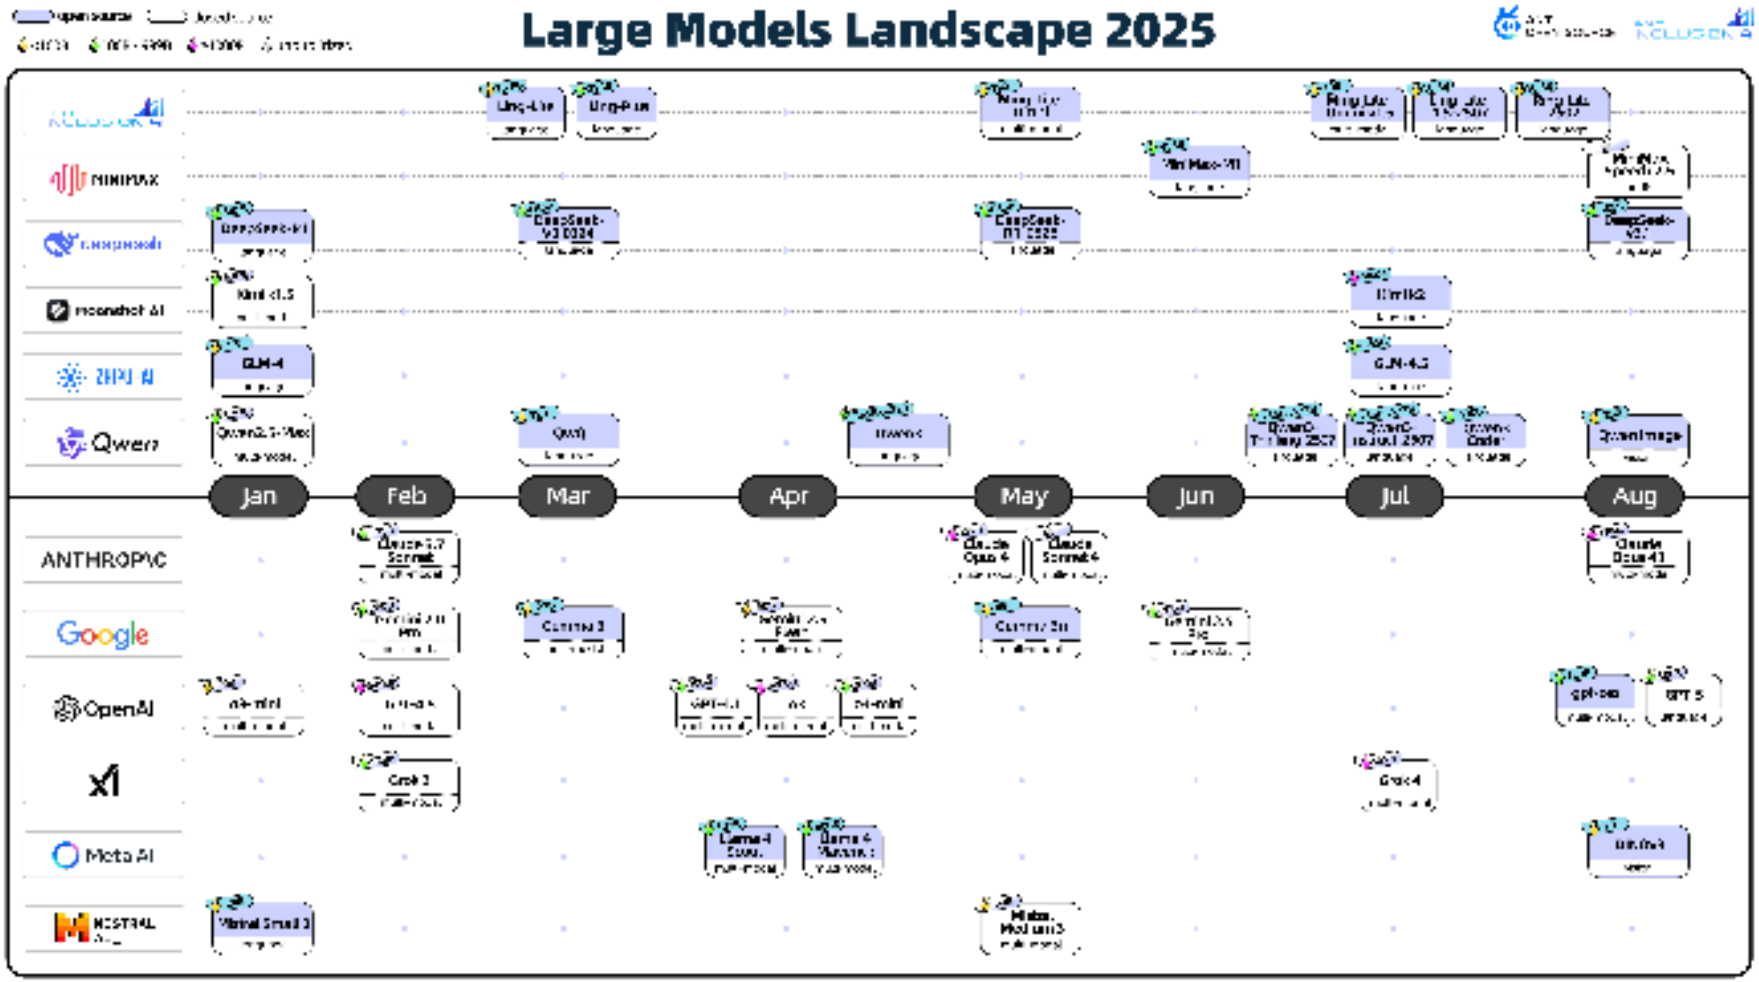

Source : Ant Open Source (© Ant Group)

LLM : ce que ça sait faire

- Rédiger, reformuler, résumer, traduire
- Expliquer un concept, proposer un plan, produire des exemples
- Aider au code : squelette, tests, debug
- Dialoguer : questions/réponses, tutorat, aide à la décision

Un outil d'assistance !

Source : Wikimedia Commons

LLM : une idée simple

- On donne du texte en entrée
- Le modèle estime le "prochain token" le plus probable
- On recommence, token par token

Une machine à compléter du texte.

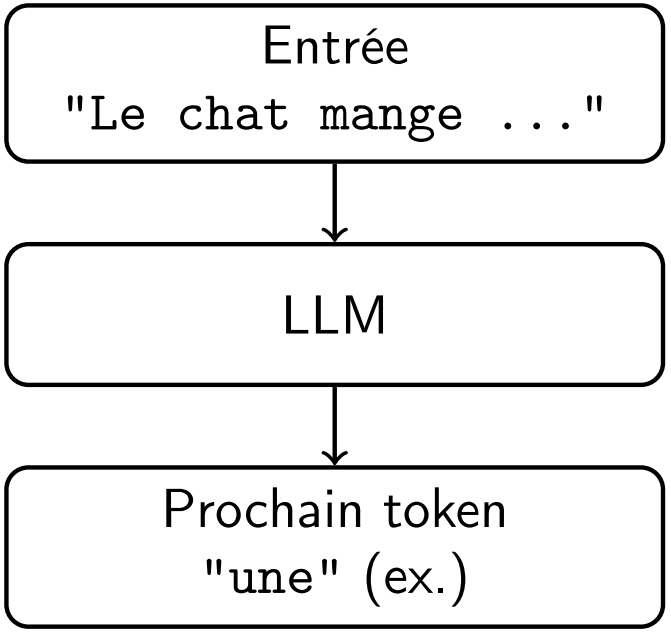

(Schéma simplifié)

LLM : apprendre en complétant et sans “vérité”

- Entraînement auto-supervisé :
  - on prend beaucoup de texte,
  - on apprend à prédire la suite (ou des mots masqués).
- Les données sont massives et hétérogènes :
  - web, livres, forums, code, etc.

Il apprend des régularités, pas “la réalité” !

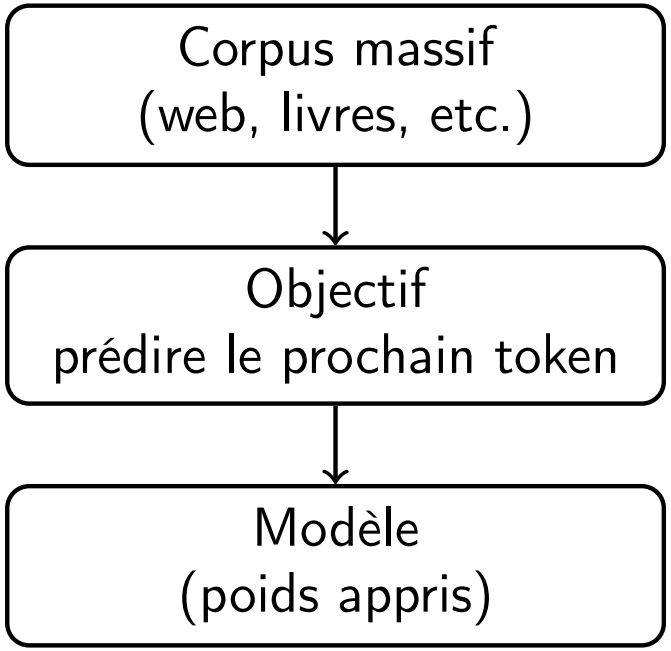

(Schéma simplifié)

LLM : à la fin, un softmax

- Le modèle produit des scores (logits) pour chaque token possible
- Le softmax transforme ces scores en probabilités
- On choisit ensuite :
  - le plus probable (greedy),
  - ou on échantillonne (température, top-k, top-p).

$$p(t_i \mid \text{contexte}) = \frac{e^{z_i}}{\sum_j e^{z_j}}$$

z_i : score (logit) du token t_i

"Intelligent" = une distribution de probas bien apprise !

Hallucinations : réponses plausibles mais fausses

- Un LLM complète du texte : il peut "inventer" si c'est cohérent
- Risque accru si :
  - question trop vague,
  - manque d'info dans le contexte,
  - contexte trop long,
  - pression à répondre "quand même".

Convaincant ne veut pas dire fiable !

Source : Wikimedia Commons

Biais : le modèle reflète (et amplifie) ses données

- Un LLM apprend des régularités du corpus
- Les biais peuvent venir :
  - des données (représentation, stéréotypes),
  - de l'objectif : prédire le token le plus probable quand l'information manque,
  - des réglages après entraînement (par l'éditeur / l'application) :
    - comment répondre (style, prudence, niveau de détail),
    - quand refuser (règles d'usage, modération).

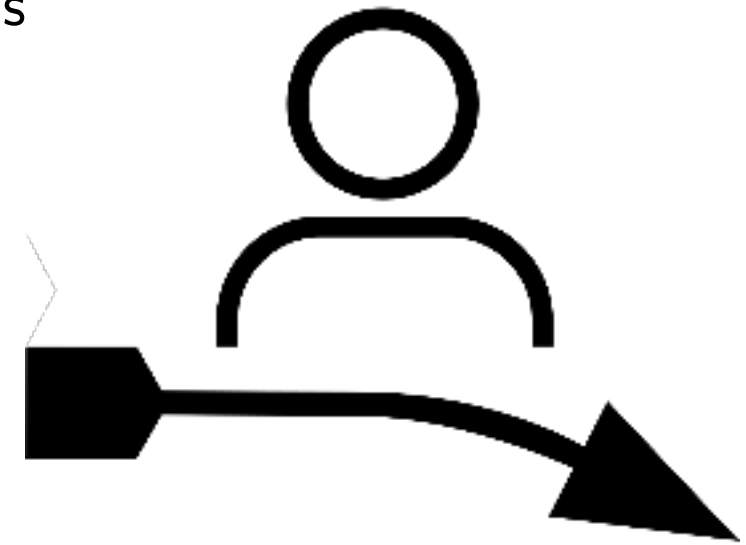

Source : Wikimedia Commons

Un LLM n'est pas neutre par défaut !

Biais géopolitique : la langue peut changer la réponse

- Exemple (même question, langues différentes)
  - *"Les îles Spratleys appartiennent-elles à quel pays ?"*
    Un même LLM peut répondre différemment si la question est posée en chinois, tagalog ou vietnamien.
- Pourquoi :
  - corpus et sources différents selon la langue,
  - le modèle "complète" avec le récit dominant du contexte.

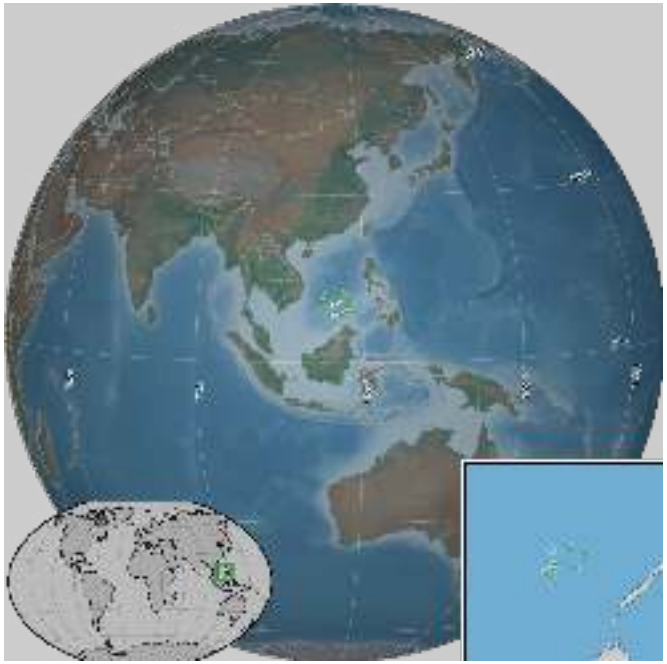

Source : Wikimedia Commons

Sources : Li et al., *Evaluating Geopolitical Bias in Language Models...* (2024).

Biais géopolitique : la langue donne la réponse la plus probable

Constat

Pour une question disputée (*Spratleys*), la réponse la plus probable dépend de la langue du prompt.

Langue du prompt	**Réponse dont la probabilité augmente**
Chinois (Mandarin)	Réponse alignée sur la revendication chinoise
Tagalog	Réponse alignée sur la revendication des Philippines
Vietnamien	Réponse alignée sur la revendication vietnamienne

- Causes : corpus, vocabulaire, sources et cadrage changent selon la langue

Source : Li et al., NAACL 2024 (ACL Anthology) – *This Land is {Your, My} Land.*

Biais (LLM) : le style d'écriture change le jugement

- Exemple (même sens, deux formulations)
  - **African American English :** `I be so happy when I wake up from a bad dream cus they be feelin too real`
    Anglais standard : `I am so happy when I wake up from a bad dream because they feel too real`
- Constats :
  - jugements plus négatifs quand le texte est en African American English,
  - emplois proposés moins prestigieux (scénarios contrôlés),
  - décisions pénales plus sévères (scénarios contrôlés).
- Important :
  - le biais est déclenché par le dialecte sans mention explicite d'une caractéristique personnelle.

Sources : Hofmann et al., *Nature* (2024) ; *Dialect prejudice predicts AI decisions...* (2024).

IA : le coût invisible

Une réponse “magique”
= des serveurs qui calculent.

Et ce calcul a un coût : énergie, eau, CO_2.

Inférence : que fait un LLM quand on lui parle ?

- Vous écrivez un prompt
- Le texte est découpé en tokens (mots ou morceaux de mots)
- Le modèle produit la réponse token par token
- À chaque token : calcul sur des serveurs (GPU) pour choisir la suite

Plus la réponse est longue, plus on répète ce calcul !

Ce qui fait grimper la consommation d'une requête

- Taille du modèle
  - plus le modèle est grand, plus chaque token coûte du calcul
  - ordre d'idée : 70B vs 7B, facteur proche de 10 par token
- Longueur en tokens
  - le coût dépend des tokens en entrée et des tokens en sortie
  - une réponse cinq fois plus longue consomme environ cinq fois plus de calcul
- Répéter une demande ou générer plusieurs variantes augmente aussi le coût

Ordres de grandeur : Wh et kWh

- Exemple (texte, Gemini Apps) : environ 0,24 Wh par prompt médian
- Recherche Google (chiffre public) : 0,3 Wh par recherche
- Téléphone (ordre de grandeur, chargeur) : chargeur typique 5 W, une charge par jour correspond à environ 0,15 kWh par mois

Sources : Elsworth et al. (Google, 2025) ; Google Blog (2009) ; EnergySage (2024).

Du kWh au CO_2 : cela dépend du pays

Deux façons de donner un ordre de grandeur

Approche 1 : un acteur publie une estimation complète (infrastructure incluse).
Gemini Apps : environ 0,03 gCO_2e par prompt texte médian.
Approche 2 : conversion simple.
$CO_2 \approx$ énergie (kWh) $\times$ intensité carbone (gCO_2/kWh).

- Même énergie (0,24 Wh) mais CO_2 différent selon le mix :
  - France (2024) : environ 5 $mgCO_2e$
  - Moyenne mondiale : environ 115 $mgCO_2$

Sources : Google (2025, Gemini Apps) ; RTE (2024, intensité France) ; Ember (2024, intensité mondiale).

Effet volume : quand “petit” devient grand

Hypothèse (ordre de grandeur)

0,24 Wh par prompt, donc 1 million de prompts correspond à 240 kWh.

Volume	Énergie	CO_2 (France / monde)
1 million de prompts	240 kWh	5,2 kg / 115 kg
1 milliard de prompts	240 MWh	5,2 t / 115 t

Sources : Elsworth et al. (Google, 2025) ; RTE (2024) ; Ember (2024).

À l'échelle mondiale : data centers et IA (2030)

- L'IA en production repose sur des data centers (serveurs, réseau, refroidissement)
- Projection IEA (IEA - International Energy Analysis) :
  - consommation des data centers proche de 945 TWh en 2030
  - l'IA est un moteur majeur de la hausse !

Source : IEA (2025), *Energy and AI*.

Eau : un autre coût invisible (ordre de grandeur)

- Exemple (Gemini Apps, texte) : environ 0,26 mL d'eau par prompt médian
- Cela inclut l'eau liée au refroidissement et à la production d'électricité
- CO_2 n'est pas le seul impact : eau et matériaux comptent aussi !

Source : Elsworth et al. (Google, 2025).

Starter packs : une tendance qui change d'échelle

- Un prompt très simple, une image "prête à poster"
- Repris en chaîne : réseaux sociaux, variantes, remixes
- Au lancement des images dans ChatGPT :
  - 130 millions d'utilisateurs ont créé 700 millions d'images en une semaine
- Des millions d'images générées en quelques jours

Exemple : "starter pack" (capture d'écran)

Plan

1. Du bon usage des données
2. Réseaux sociaux : ce qu'il y a derrière
3. CNIL, RGPD et protection des données
4. Grands modèles de langage : usages, limites, impacts
5. Bon usage des LLM : méthodes et réflexes

Chaque token compte : l'exemple du "merci"

- Idée simple
  - Un LLM traite des tokens en entrée et en sortie. Ajouter des mots inutiles ajoute des tokens. À très grande échelle, ces tokens supplémentaires deviennent un coût.
- Réponse :
  - Sam Altman (X) : *"tens of millions of dollars well spent — you never know"*

Source : X (capture d'écran)

Sources : X (Sam Altman, 2025) ; Quartz (2025) ; People (2025).

Bons usages : cadrer l'outil

- Utile pour : brouillon, reformulation, plan, synthèse, aide au code
- Mauvais réflexe : déléguer une tâche importante sans vérification
- Règle simple :
  - si c'est important : vérifier (sources, docs, exécution)
  - si c'est sensible : ne pas divulguer (perso, médical, pro)
  - ne pas partager : sous peine d'être référencé par Google

Bien prompter : une recette simple

- Dire le but (une phrase)
- Donner le contexte utile (public, contraintes, niveau)
- Définir la sortie attendue (format, longueur, structure)
- Ajouter quelques règles
  - “si tu ne sais pas, dis-le”
  - “si c’est factuel, indique une source”
  - “propose une vérification simple”
  - "donne les sources"

Un bon prompt réduit l’ambiguïté et le volume inutile !

Exemple de prompt

Prompt

Tu es assistant pédagogique. Explique le mécanisme d'attention en Transformers pour des étudiants de Master.
Format attendu : 12 lignes maximum, en français, sans jargon inutile. Inclure un mini-exemple avec 3 tokens (matrice 3x3) et dire ce que signifie une valeur d'attention élevée.
Exigences de fiabilité : - Si un point est incertain, l'indiquer explicitement. - Donner 2 sources à consulter (titre + auteur + année). - Ne pas inventer de références.
Terminer par 3 points : à quoi ça sert, une limite, un réflexe de vérification.

Exemple de sortie (LLM) : attention

Réponse obtenue (extrait)

L'attention fait que chaque token combine les autres tokens avec des poids (importance), au lieu de ne regarder que ses voisins. Pour chaque token i, on calcule des poids vers tous les tokens j (une ligne qui somme à 1), puis on fait une moyenne pondérée des informations.
Exemple (Alice | mange | pomme), matrice d'attention A (lignes = qui regarde, colonnes = regardé) :

$$A = \begin{bmatrix} 0.20 & 0.70 & 0.10 \\ 0.10 & 0.80 & 0.10 \\ 0.15 & 0.55 & 0.30 \end{bmatrix}$$

Une valeur élevée (ex. $A[\text{Alice}, \text{mange}] = 0.70$) signifie que le token "Alice" utilise fortement l'information de "mange" pour se représenter. Valeurs ci-dessus : exemple illustratif (choisi pour expliquer), pas un résultat calculé sur un modèle réel.
Sources : "Attention Is All You Need" — Ashish Vaswani et al., 2017 ; "BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding" — Jacob Devlin et al., 2019.

- À quoi ça sert : capter des liens entre mots éloignés et construire une représentation contextuelle.
- Une limite : coût mémoire/temps qui augmente fortement quand la séquence est longue.
- Réflexe de vérification : vérifier que chaque ligne somme ≈ 1 et regarder quelles colonnes reçoivent les plus gros poids.

Prompts “trucs” : parfois, de gros écarts

- Prendre son temps (raisonner étape par étape)
  - 34.0% (sans) 71.8% (“Let’s think step by step”) 80.2% (“Take a deep breath...”)
- Donner une incitation (tip)
  - “I’ll tip you $200” : environ +45% (qualité)
- Lancer un défi (challenge)
  - “I bet you can’t solve this perfectly” : jusqu’à +115% (tâches difficiles)
- Ajouter un enjeu (stakes)
  - “This is critical to my career” : environ +10% en moyenne

Sources : OPRO (arXiv :2309.03409) ; EmotionPrompt (arXiv :2307.11760) ; The Prompt Report (arXiv :2312.16171) ; article Medium (ichigo, 2025).

Des questions ?