Extraction de connaissances et approches d'apprentissage

Principes, exemples, sorties attendues

Université de Montpellier – LIRMM

HAI817I

Pascal Poncelet
Pascal.Poncelet@lirmm.fr
http://www.lirmm.fr/~poncelet

Plan

1. Introduction : pourquoi extraire des connaissances ?
2. Processus d'extraction de connaissances
3. Apprentissage supervisé
4. Apprentissage non supervisé
5. Apprentissage semi-supervisé
6. Autres types d'apprentissage
7. Conclusions

Plan

1. Introduction : pourquoi extraire des connaissances ?
2. Processus d'extraction de connaissances
3. Apprentissage supervisé
4. Apprentissage non supervisé
5. Apprentissage semi-supervisé
6. Autres types d'apprentissage
7. Conclusions

Pourquoi extraire des connaissances ?

- Les données décrivent des événements, pas des décisions.
- On cherche des signaux exploitables : prioriser, détecter, recommander, prévoir.
- On retrouve les mêmes idées dans des domaines très différents :
  - santé : dépistage, triage, aide à l'interprétation,
  - sciences du vivant : interactions moléculaires, conception,
  - environnement : risques, prévision, détection d'événements,
  - retail et finance : prévision de la demande, risque, détection d'anomalies,
  - plateformes : recommandation, modération, fraude, structuration,
  - industrie : maintenance, anomalies sur capteurs.
- Sorties typiques : score, liste triée, groupe, alerte, règle.

Santé : dépistage et triage (imagerie, urgence)

- Entrées : images (radio, scanner, mammographie) + contexte patient.
- Objectif : aider à repérer, prioriser, réduire les oublis.
- Exemples :
  - score de suspicion sur une mammographie,
  - tri des examens à relire en priorité,
  - alerte sur un cas atypique (sans poser le diagnostic à la place du médecin).
- Sorties : score, liste priorisée, zones d'intérêt.

Source : Wikimedia Commons

Sources : Nature, International evaluation of an AI system for breast cancer screening (McKinney et al., 2020) ; WHO, Ethics and governance of artificial intelligence for health (2021).

Sciences du vivant : structures et interactions (AlphaFold)

- Entrées : séquences (protéines, ADN/ARN) et partenaires possibles.
- Objectif : prédire une structure 3D et des interactions probables.
- Utilité : accélérer l'analyse et générer des hypothèses testables en laboratoire.
- Sorties : structure 3D, score de confiance, liste de complexes candidats.

Source : Wikimedia Commons

Sources : Nature, Highly accurate protein structure prediction with AlphaFold (Jumper et al., 2021) ; Nature, Accurate structure prediction of biomolecular interactions with AlphaFold 3 (Abramson et al., 2024).

Environnement : surveillance et alerte (incendies, inondations)

- Entrées : images satellite, météo, données au sol.
- Objectif : suivre un événement, estimer une extension, produire des cartes utiles.
- Exemples :
  - surface brûlée et évolution d'un incendie,
  - zones inondées et infrastructures impactées,
  - indice de risque et cartographie rapide.
- Sorties : cartes, alertes, indicateurs par zone.

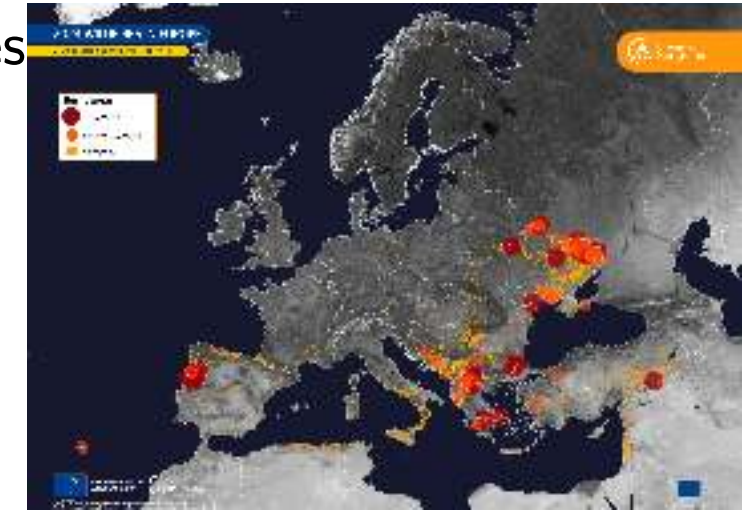

Source : Wikimedia Commons

Sources : Copernicus EMS, On-Demand Mapping ; EFFIS (Copernicus), European Forest Fire Information System.

Retail et finance : prévoir, détecter, contrôler le risque

- Entrées : ventes, prix, stocks, transactions, comportements.
- Objectif : réduire l'incertitude et limiter les pertes.
- Exemples :
  - prévision de la demande et optimisation des stocks,
  - détection de fraude en temps réel,
  - scoring de risque et monitoring d'anomalies.
- Sorties : prévisions, scores de risque, alertes priorisées.

Source : Wikimedia Commons

Sources : OECD, Artificial Intelligence, Machine Learning and Big Data in Finance (2021) ; FSB, Monitoring Adoption of Artificial Intelligence and Related Vulnerabilities (2025).

Plateformes : recommandation, modération, structuration

- Entrées : clics, vues, abonnements, texte, images, relations entre entités.
- Objectif : personnaliser sans perdre le contrôle.
- Exemples :
  - ranking de contenus ou de produits,
  - détection d'abus et priorisation de la modération,
  - graphes de connaissances (liens entre personnes, lieux, œuvres, concepts).
- Sorties : liste triée, drapeaux, liens d'entités, clusters.

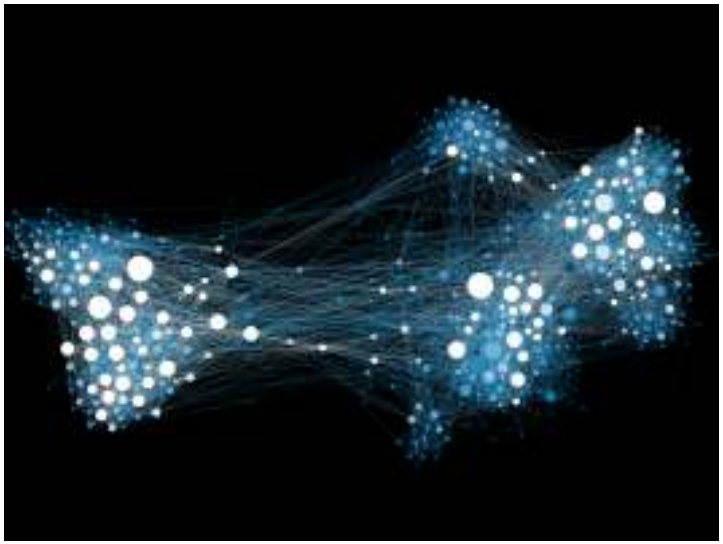

Source : Wikimedia Commons

Sources : Wikidata (Commons), Wikidata knowledge graphs ; Wikimedia Commons, Social Network Visualization (Grandjean, 2016).

Industrie : maintenance prédictive (capteurs, séries temporelles)

- Entrées : vibrations, température, courant moteur, logs machines.
- Objectif : éviter l'arrêt non planifié, planifier les interventions.
- Exemples :
  - détection d'une dérive progressive,
  - estimation d'un risque de panne à court terme,
  - priorisation des équipements à inspecter.
- Sorties : score d'anomalie, alerte, liste d'équipements à traiter.

Source : Wikimedia Commons

De la question au résultat

Question	Exemple	Sortie
Que mettre en priorité ?	modération, support, triage	score + seuil
Que recommander ?	recherche, contenus, produits	liste triée
Que regrouper ?	profils, comportements	segments
Que surveiller ?	fraude, capteurs, sécurité	alerte
Que prévoir ?	demande, risque	valeur

Plan

1. Introduction : pourquoi extraire des connaissances ?
2. Processus d'extraction de connaissances
3. Apprentissage supervisé
4. Apprentissage non supervisé
5. Apprentissage semi-supervisé
6. Autres types d'apprentissage
7. Conclusions

Processus KDD : les étapes

- Un projet démarre par une question et une sortie attendue.
- Les étapes se répètent souvent (on corrige, on améliore, on recommence).
- Les difficultés sont rarement dans l'algorithme, souvent dans les données et le cadrage.

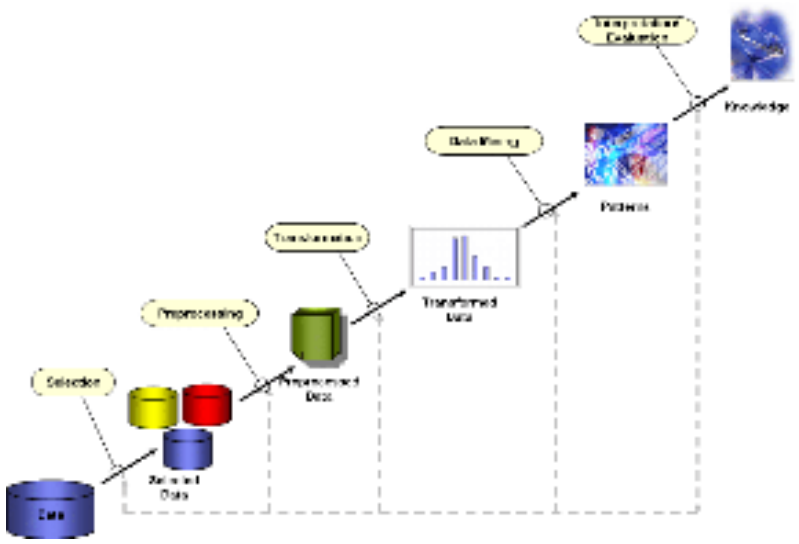

Source : Wikimedia Commons

Sources : U. Fayyad, G. Piatetsky-Shapiro, P. Smyth, The KDD process for extracting useful knowledge from volumes of data (Communications of the ACM, 1996) ; C. Shearer, The CRISP-DM Model: The New Blueprint for Data Mining (2000).

1. Cadrer le problème

- Point de départ : une question formulée comme une tâche.
- Choisir la sortie attendue :
  - score = prioriser,
  - classe = décider,
  - valeur = prévoir,
  - groupe = segmenter.
- Définir ce qui compte : coût des erreurs, délai, volume, contraintes de traçabilité.
- Baseline simple : une règle ou un modèle très simple pour avoir un repère.

2. Données : ce qui change tout

- Qualité : manquants, doublons, incohérences, outliers, dérive.
- Représentativité : le train couvre-t-il bien la population cible (sur/sous-représentation) ?
- Disponibilité : n'utiliser que des variables connues au moment de la décision (éviter la fuite d'information).
- Préparation :
  - encodages, normalisation, agrégations, fenêtres temporelles,
  - séparation apprentissage / validation / test (en temporel : respecter l'ordre du temps).

3. Apprendre, valider, livrer

- Apprentissage : choix d'une méthode, entraînement, réglages.
- Validation : mesurer sur des données non vues, regarder les erreurs coûteuses.
- Livraison : intégrer dans un flux (API, batch, tableau de bord), documenter.
- Suivi : dérive des données, dérive des performances, réapprentissage si nécessaire.

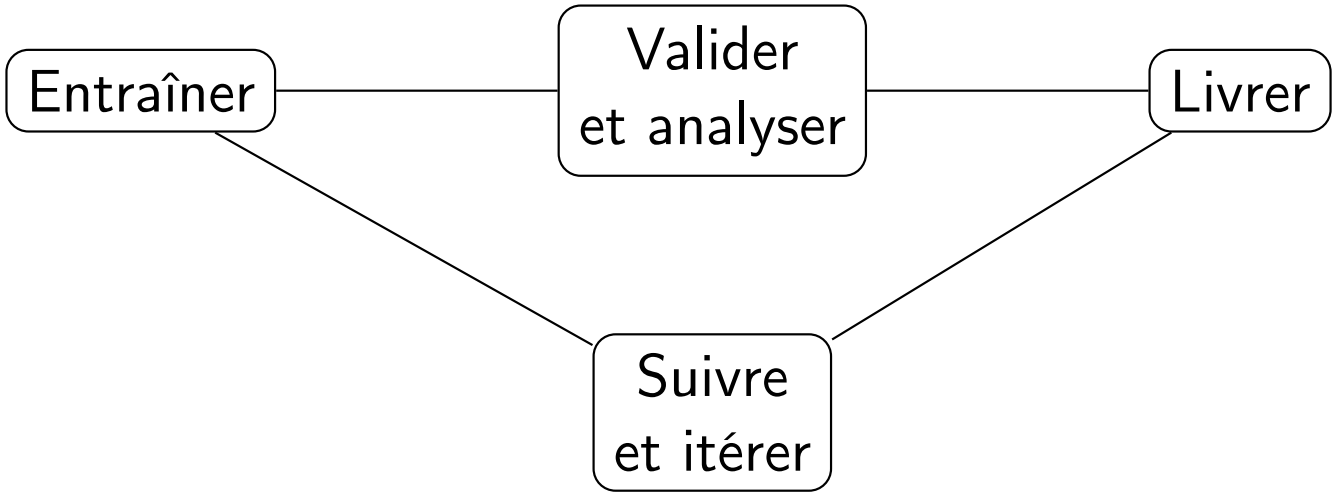

Quel apprentissage choisir selon les données ?

- Après le cadrage et la préparation, une question simple guide le choix :
  - a-t-on des labels ?
  - sont-ils fiables ?
  - combien peut-on en obtenir ?

Avec labels

- supervisé : labels fiables
- weak supervision : labels faibles (règles, heuristiques, distant supervision)

Sans labels

- non supervisé : structure (groupes, représentations)

Entre les deux

- semi-supervisé : peu de labels + beaucoup de non étiqueté
- apprentissage actif : choisir quoi annoter pour progresser vite

Pré-entraînement sans labels, puis adaptation

- auto-supervisé : tâche de prétexte, puis transfert

Plan

1. Introduction : pourquoi extraire des connaissances ?
2. Processus d'extraction de connaissances
3. Apprentissage supervisé
4. Apprentissage non supervisé
5. Apprentissage semi-supervisé
6. Autres types d'apprentissage
7. Conclusions

Apprentissage supervisé : données et sorties possibles

- Données étiquetées : chaque ligne = une entrée X et une sortie attendue y.
- Objectif : apprendre une fonction f telle que $y \approx f(X)$.
- Deux sorties classiques :
  - classification : y est une classe,
  - régression : y est une valeur.

$$X \in \mathbb{R}^{n \times p} : n \text{ exemples, } p \text{ variables}$$

$$y \in \{1, \ldots, K\}^n \text{ (classification)} \quad \text{ou} \quad y \in \mathbb{R}^n \text{ (régression)}$$

client	âge	achat_30j	visites_7j	y (classe)
A	22	1	5	répond (1)
B	47	0	1	ne répond pas (0)
C	35	3	4	répond (1)

En régression, y serait une valeur (ex. dépense_30j = 120.5 pour A, 121.2 pour B, etc.).

Supervisé : entraînement vs test (intuition)

- On découpe les données en deux parties :
  - train : apprendre le modèle,
  - test : vérifier sur des exemples non vus.

Évaluation sur le test : on compare les prédictions aux vraies étiquettes (combien d'erreurs ? quels types d'erreurs ?)

id	âge	achat_30j	visites_7j	y (classe)	rôle
A01	22	1	5	1	train
A02	47	0	1	0	train
A03	35	3	4	1	train
A04	29	0	2	0	train
A05	41	2	6	1	train
A06	31	1	3	0	train
A07	55	4	2	1	train
A08	26	0	4	0	train
T01	38	2	1	1	test
T02	24	0	6	0	test
T03	49	3	0	1	test

Le test (en rouge) sert à estimer ce que le modèle fera sur de nouveaux clients.

Supervisé : biais et généralisation (idée simple)

- Un modèle apprend des régularités présentes dans les données, y compris des biais.
- Sources fréquentes :
  - biais de sélection : le train n'est pas représentatif de la population cible (sur/sous-représentation),
  - biais de mesure : variables ou labels bruités, incomplets, annotés différemment selon les cas.
- Intuition : un score global peut cacher des erreurs concentrées sur certains cas.
- Réflexes :
  - comparer les distributions (train vs test, sous-populations),
  - regarder des exemples d'erreurs, pas seulement un chiffre.

Supervisé : classes déséquilibrées

- Cas fréquent : une classe est rare (fraude, incident, maladie, abus).

- Ici, les labels sont fiables ; le problème est la faible fréquence de la classe rare.
- Risque : un modèle peut sembler bon en prédisant presque toujours la classe majoritaire.
- Réflexes :
  - découpage stratifié (mêmes proportions dans train/test),
  - pondération des classes (erreurs sur la classe rare plus pénalisées),
  - sur/sous-échantillonnage (équilibrer le train).

Supervisé : labels faibles (weak supervision)

- Cas fréquent : annoter à la main est trop coûteux, ou les labels sont incomplets.
- On parle de *weak supervision* : un label y produit automatiquement avec du bruit.
- Différence avec les classes déséquilibrées : ici, c'est la qualité du label qui pose problème.
- Exemples :
  - règle : si un message contient `URGENT` et un lien, alors `spam`,
  - heuristique : si remboursement en moins de 2 minutes, alors `suspect`,
  - distant supervision : une base externe fournit des couples (entité, type) et on annote automatiquement dans un corpus (ex. *Paris* = `VILLE`), avec des erreurs possibles (ex. *Paris Hilton*).
- Réflexe : garder un petit jeu de labels fiables pour mesurer, corriger, ajuster les règles.

Supervisé : corrélations et décisions indirectes

- Attention : une variable peut servir de raccourci et conduire à des décisions indirectes.
- Exemple : code postal.
  - même sans variable `revenu`, le code postal peut être corrélé au revenu moyen,
  - un modèle de crédit/assurance peut alors pénaliser certains quartiers sans jamais voir `revenu`.
- Réflexes :
  - tester l'impact quand on retire une variable,
  - regarder les erreurs par sous-population,
  - ajuster les variables quand on observe des effets indésirables (processus itératif).

Supervisé : familles de modèles

- Familles courantes (souvent déclinées en classification et en régression) :
  - modèles linéaires : régression linéaire, régression logistique,
  - voisinage : k-NN,
  - méthodes à marge : SVM, SVR,
  - arbres et ensembles : arbres, Random Forest, Gradient Boosting.
- Sortie : une prédiction $\hat{y}$ et souvent un score ou une incertitude.
- No Free Lunch : le meilleur choix dépend des données et du contexte.

Exemple : campagne mailing (classification)

- Objectif : décider à qui envoyer un courrier (ou email/push) pour maximiser le gain.
- Données : pour chaque client, des variables X et une étiquette y :
  - $y = 1$: le client répond
  - $y = 0$: le client ne répond pas
- Hypothèses de coût/gain (exemple volontairement simple ☺) :
  - envoi sans réponse : coût 50
  - réponse : gain 100
  - ne pas envoyer à un client qui aurait répondu : perte 100 (opportunité)
- Sortie attendue : un score par client (probabilité de réponse), puis une décision.

Du jeu de données au ciblage (vue opérationnelle)

Base clients
X : variables (profil, historique, canal, etc.)
y : a répondu (1) / n'a pas répondu (0)

Apprentissage (sur train)
apprendre un modèle qui produit un score de réponse

Scoring et tri
score élevé = client prioritaire

Décision
envoyer selon budget et seuil choisi

Exemple de résultat : segments avec probabilités (arbre)

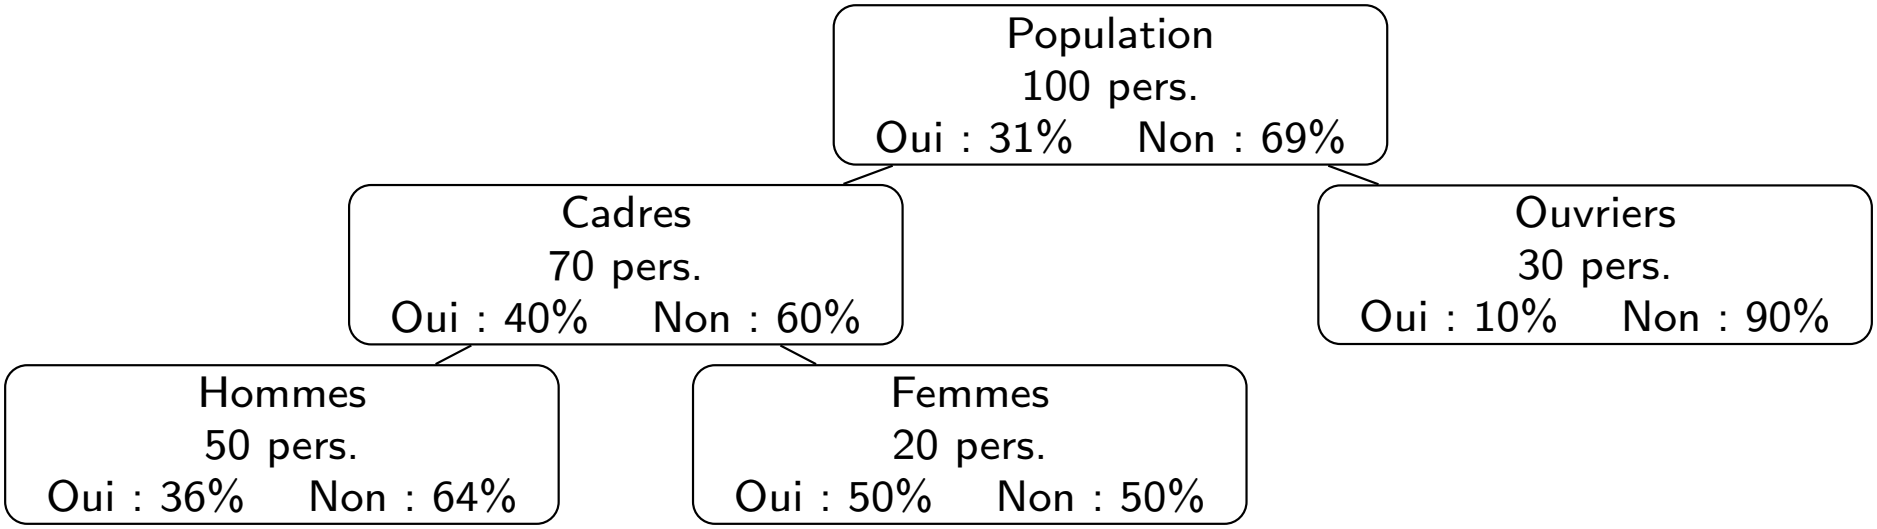

Exemple de réponses

Décider : quels segments contacter ? (intuition)

- À partir des taux Oui/Non, on peut estimer un gain attendu par segment.
- Gain attendu (exemple) :
  - Femmes cadres : $10 \times 100 - 10 \times 50 = 500$
  - Hommes cadres : $18 \times 100 - 32 \times 50 = 200$
  - Cadres (tous) : $(70 \times 40\%) \times 100 - (70 \times 60\%) \times 50 = 700$
  - Ouvriers : $3 \times 100 - 27 \times 50 = -1050$
  - Population : $31 \times 100 - 69 \times 50 = -350$
- Décision : Mailing à l'ensemble des cadres ou uniquement aux femmes cadres !

Plan

1. Introduction : pourquoi extraire des connaissances ?
2. Processus d'extraction de connaissances
3. Apprentissage supervisé
4. Apprentissage non supervisé
5. Apprentissage semi-supervisé
6. Autres types d'apprentissage
7. Conclusions

Apprentissage non supervisé : principe

- Données non étiquetées : on observe X, mais pas de y.
- Objectif : découvrir une structure utile dans les données.
- Trois sorties typiques :
  - groupes (clustering) : segmenter,
  - représentation (réduction de dimension) : visualiser ou compresser,
  - motifs et règles : extraire des régularités interprétables.

$X \in \mathbb{R}^{n \times p}$: n exemples, p variables

Pas de y : on cherche structure, groupes, représentation, régularités

Non supervisé : clustering (segmentation)

- Idée : des exemples proches dans l'espace des variables sont mis dans le même groupe.
- Sortie : un groupe $c \in \{1, \ldots, K\}$ pour chaque ligne de X.
- Exemples de méthodes : k-means, clustering hiérarchique, DBSCAN.

client	âge	achat_30j	visites_7j	groupe
A	22	1	5	1
B	47	0	1	2
C	35	3	4	1
D	29	0	2	2
E	41	2	6	1

Clustering : comment juger si c'est bon ?

- Pas de vérité terrain : on cherche de la cohérence et de la stabilité.
- Intuition :
  - groupes compacts : les points d'un même groupe se ressemblent,
  - groupes séparés : deux groupes sont différents,
  - stabilité : des groupes similaires apparaissent quand on relance sur un autre échantillon.
- Quelques critères usuels :
  - silhouette (compact + séparé),
  - inertie / SSE (k-means),
  - validation métier : groupes interprétables et actionnables.

Non supervisé : réduction de dimension (visualiser)

- Idée : représenter X avec moins de variables, en gardant de la structure.
- Sortie : une représentation $Z \in \mathbb{R}^{n \times d}$ (souvent $d = 2$).
- Usage : visualiser des groupes, repérer des outliers, compresser des données.

X (beaucoup de variables)	projection	Z (2 variables, ex. 2D)

Exemples de méthodes : PCA, t-SNE, UMAP.

Non supervisé : motifs fréquents (paniers)

- Données : transactions, paniers, événements (présent/absent).
- Objectif : trouver des co-occurrences fréquentes.
- Sortie : un motif (ensemble d'items) fréquent.

transaction	items
T1	{lait, pain, beurre}
T2	{lait, pain}
T3	{pain, couches, bière}
T4	{lait, pain, couches}

Exemple de motif fréquent : {lait, pain}.

Outil connu : SPMF (bibliothèque open-source pour l'extraction de motifs).

Sources : SPMF, Documentation et téléchargement.

Non supervisé : règles d'association

- À partir des motifs fréquents, on forme des règles :
  - si A est présent, B est souvent présent.
- Sortie : une règle $A \Rightarrow B$ (régularité interprétable).
- Usage : recommandations, organisation de catalogue, analyse de comportements.

Exemple : {lait, pain} est fréquent
Règle : {lait} implique souvent {pain}

Plan

1. Introduction : pourquoi extraire des connaissances ?
2. Processus d'extraction de connaissances
3. Apprentissage supervisé
4. Apprentissage non supervisé
5. Apprentissage semi-supervisé
6. Autres types d'apprentissage
7. Conclusions

Semi-supervisé : ce qui change par rapport au supervisé

- Supervisé classique :
  - on apprend uniquement sur des données étiquetées (X_L, y_L),
  - puis on prédit sur de nouvelles données.
- Semi-supervisé :
  - on a peu de données étiquetées (X_L, y_L),
  - on a beaucoup de données sans labels X_U,
  - on utilise aussi X_U pendant l'apprentissage pour améliorer le modèle.

	données pour apprendre	données sans labels utilisées ?
supervisé	(X_L, y_L)	non
semi-supervisé	$(X_L, y_L) + X_U$	oui

Semi-supervisé : une idée simple (pseudo-labels)

- Étape 1 : entraîner un modèle sur le petit jeu étiqueté (X_L, y_L).
- Étape 2 : prédire sur X_U et ne garder que les exemples très confiants (ex. probabilité > 0.95).
- Étape 3 : ré-entraîner en ajoutant ces exemples à l'entraînement.
- **Attention** : X_U n'est pas un jeu de test ; le test reste séparé et étiqueté.

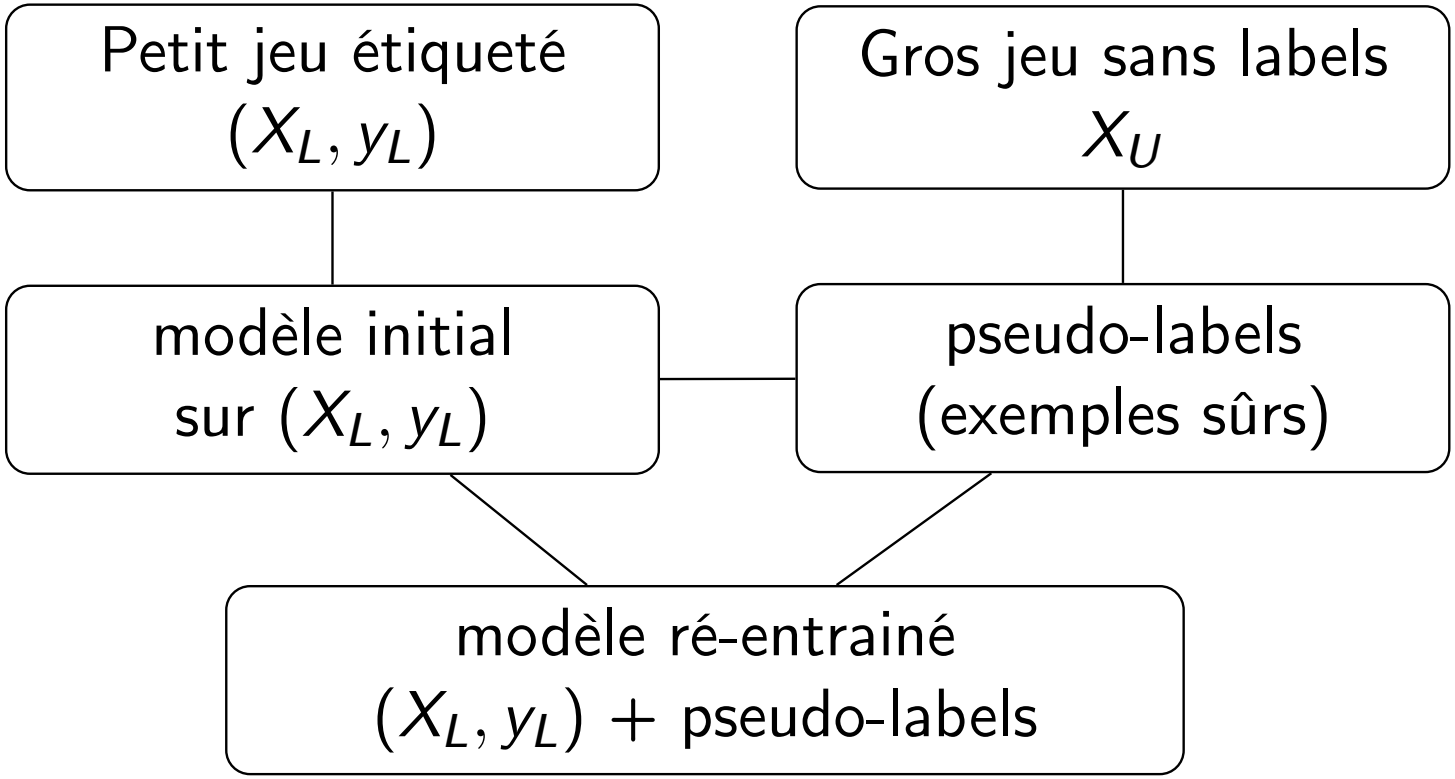

Pseudo-labels : quand garder un label ?

- On ne sait pas être certain : on applique des critères pratiques pour limiter le bruit.
- Exemples de critères :
  - seuil de confiance : garder si $p(y = 1 \mid x) > 0.95$ (pseudo-label $= 1$) ou si $p(y = 1 \mid x) < 0.05$ (pseudo-label $= 0$),
  - accord : garder seulement si plusieurs modèles (ou plusieurs relances) prédisent la même classe,
  - stabilité : la prédiction ne change pas avec de petites perturbations de l'exemple.
- Vérification : si l'évaluation sur le vrai test étiqueté ne s'améliore pas, on ajuste.

Semi-supervisé : algorithmes classiques ou dédiés

- Deux options :
  - utiliser un classifieur classique et une stratégie itérative (pseudo-labels),
  - utiliser une méthode dédiée au semi-supervisé.
- Exemple de méthode dédiée : propagation de labels (sur graphe de voisinage)
  - construire un graphe de voisins (k plus proches voisins),
  - les labels connus influencent les points non étiquetés (vote, diffusion),
  - méthodes : Label Propagation, Label Spreading, Graph Transduction.
- C'est toujours itératif ! On vérifie toujours sur un vrai jeu de test étiqueté.

Plan

1. Introduction : pourquoi extraire des connaissances ?
2. Processus d'extraction de connaissances
3. Apprentissage supervisé
4. Apprentissage non supervisé
5. Apprentissage semi-supervisé
6. Autres types d'apprentissage
7. Conclusions

Autres types d'apprentissage

- Quand l'annotation est le point limitant ou que le problème n'est pas un simple (X, y).
- Trois cas fréquents :
  - apprentissage actif : on choisit quoi annoter,
  - auto-supervisé : on apprend d'abord sans labels puis on adapte sur une tâche,
  - renforcement : on apprend à décider dans le temps via une récompense.
- Sorties typiques :
  - actif : un meilleur modèle supervisé avec moins d'annotations,
  - auto-supervisé : une représentation ("embeddings"), puis un modèle adapté,
  - renforcement : une stratégie de décision.

Apprentissage actif : principe

- Contexte : on peut obtenir des labels, mais chaque annotation coûte du temps ou de l'argent.
- Idée : choisir les exemples à annoter qui feront le plus progresser le modèle.
- Exemple du mailing :
  - le modèle hésite pour certains clients (score proche de 0.5),
  - on demande un label sur ces cas plutôt que sur des cas évidents,
  - on ré-entraîne, puis on recommence.
- Exemples de méthodes :
  - incertitude (sélection des cas ambigus),
  - comité (plusieurs modèles votent, on annote quand ils divergent),
  - diversité (éviter d'annoter 20 cas quasi identiques).
- Sortie : un modèle supervisé avec moins d'annotations.

Auto-supervisé : principe

- Idée : apprendre à partir de X seul en se donnant une tâche automatique.
- Exemple texte :
  - on masque des mots dans des messages et on apprend à les prédire,
  - on obtient une représentation des messages ("embedding") qui capture du sens.
- Ensuite, on réutilise cette représentation pour une vraie tâche, avec quelques labels :
  - on ajoute une petite couche de décision,
  - on apprend sur un petit jeu annoté (ex. spam / non spam, répond / ne répond pas).
- Exemples de méthodes (idées) :
  - texte : mot masqué, prochain mot,
  - image : autoencodeur, partie manquante, rotation.
- Sortie : une représentation puis un modèle adapté à une tâche précise.

Renforcement : principe

- Problème différent : on apprend à décider dans le temps, pas à prédire y pour chaque ligne.
- On a : un état, une action, une récompense (gain ou coût).
- Exemple simple : gestion d'un budget de campagnes sur plusieurs jours
  - actions : répartir le budget entre canaux,
  - récompense : conversions, coût, contraintes,
  - les décisions d'aujourd'hui influencent les données de demain.
- Exemples de méthodes : Q-learning, SARSA.
- Sortie : une stratégie de décision.

Plan

1. Introduction : pourquoi extraire des connaissances ?
2. Processus d'extraction de connaissances
3. Apprentissage supervisé
4. Apprentissage non supervisé
5. Apprentissage semi-supervisé
6. Autres types d'apprentissage
7. Conclusions

Conclusion : ce qu'il faut retenir

- Une extraction de connaissances commence par une question claire et une sortie exploitable.
- Le choix de l'apprentissage dépend surtout des labels : existence, fiabilité, quantité.
- Les performances ne se résument pas à un chiffre : il faut regarder quelles erreurs on fait.
- Les modèles apprennent ce qu'on leur donne : biais, déséquilibres, labels faibles, corrélations.
- Le processus est itératif : on ajuste la question, les variables, le protocole d'évaluation.

Conclusion : données avant algorithmes

- En pratique, le plus gros effort n'est pas l'algorithme :
  - rendre les données utilisables (nettoyer, structurer, intégrer),
  - définir des variables pertinentes (ce qui est disponible au moment de décider),
  - vérifier représentativité et dérives,
  - construire un découpage train/test cohérent (temps, individus, groupes).
- Règle empirique (ordre de grandeur) : souvent 80% du travail sur les données, 20% sur le modèle.
- Quand les données sont maîtrisées, le choix du modèle devient souvent un problème plus simple.

Des questions ?